TRƯỜNG ĐẠI HỌC THỦY LỢI

KHOA CÔNG NGHỆ THÔNG TIN

BÀI TẬP LỚN
KHAI PHÁ DỮ LIỆU

ĐỀ TÀI:
KHAI PHÁ DỮ LIỆU BẠO LỰC HỌC ĐƯỜNG

Giảng viên hướng dẫn: TS. Trần Mạnh Tuấn
Sinh viên: Nguyễn Thị Phương Anh - 2251161942
Nguyễn Minh Hiếu - 2251162001

Lớp: 64TTNT2

Hà Nội - 2024

LỜI NÓI ĐẦU

Bạo lực học đường từ lâu đã trở thành một vấn đề nhức nhối, gây ảnh hưởng nghiêm trọng đến sự phát triển của thế hệ tương lai trên toàn thế giới. Qua những số liệu thực tế, chúng em nhận thấy sự cần thiết trong việc ứng dụng thực tiễn và sự hữu ích đề tài này sẽ mang lại cho quá trình học tập của mình. Như vậy, chúng em đã quyết định triển khai Đề tài *"Khai phá dữ liệu về bạo lực học đường"* để tìm ra các yếu tố chính gây ảnh hưởng đến việc học sinh trở thành nạn nhân của bạo lực học đường.

Mục tiêu chính của chúng em là áp dụng các kỹ thuật khai phá dữ liệu để phân tích mối quan hệ giữa các yếu tố như giới tính, độ tuổi, và loại bạo lực, từ đó xác định những yếu tố quan trọng nhất dẫn tới bạo lực học đường.

Chúng em tin rằng đề tài sẽ giúp các trường học và cơ quan giáo dục có cái nhìn rõ ràng hơn về tình trạng bạo lực học đường hiện nay, qua đó thực hiện những biện pháp can thiệp và phòng ngừa bạo lực học đường một cách hiệu quả.

Xin chân thành cảm ơn thầy Trần Mạnh Tuấn đã tận tình hướng dẫn và hỗ trợ chúng em hoàn thành Đề tài "*Khai phá dữ liệu về bạo lực học đường*".

Chúng em xin chân thành cảm ơn!

MỤC LỤC

PHẦN I. MÔ TẢ BÀI TOÁN

1. Đặt vấn đề

Theo báo cáo của Tổ chức Giáo dục, Khoa học và Văn hóa Liên hợp quốc (UNESCO) vào năm 2021, khoảng ⅓ số lượng học sinh từ 13 đến 15 tuổi trên toàn thế giới đã từng trải qua ít nhất một hình thức bạo lực học đường. Con số này tương đương với hơn 150 triệu học sinh trên toàn cầu cho thấy quy mô thật sự đáng báo động của vấn đề này.

Tại Việt Nam, theo một khảo sát được thực hiện vào năm 2022, hơn 40% học sinh đã từng chứng kiến hoặc trải nghiệm bạo lực học đường, với các hình thức như đánh đập, châm chọc, và bắt nạt qua mạng xã hội. Các con số này cho thấy rằng không chỉ học sinh mà cả giáo viên và phụ huynh đều cần phải quan tâm nhiều hơn đến tình trạng này. Nhiều nghiên cứu đã chỉ ra rằng những học sinh từng trải qua bạo lực học đường có khả năng gặp phải các vấn đề về tâm lý như lo âu, trầm cảm, và khó khăn trong việc thiết lập các mối quan hệ xã hội.

Bên cạnh đó, bạo lực học đường còn ảnh hưởng đến thành tích học tập. Một nghiên cứu tại Hoa Kỳ cho thấy rằng những học sinh bị bắt nạt có nguy cơ bỏ học cao gấp đôi so với các bạn cùng trang lứa. Điều này không chỉ làm giảm chất lượng giáo dục mà còn dẫn đến việc tăng cường sự chênh lệch trong cơ hội phát triển cá nhân và nghề nghiệp sau này.

Trước tình trạng báo động này, chúng em triển khai đề tài không chỉ để tìm hiểu nguyên nhân mà còn làm rõ các yếu tố ảnh hưởng cũng như mức độ nghiêm trọng của bạo lực học đường.

Tổng quan bài toán

Dataset bao gồm các thuộc tính mô tả tình trạng bạo lực học đường. Mục tiêu của dự án là áp dụng các kỹ thuật khai phá dữ liệu để phân tích mối quan hệ giữa các yếu tố như giới tính, độ tuổi, và loại bạo lực, từ đó xác định những yếu tố quan trọng nhất dẫn tới bạo lực học đường.

2. Quy trình thực hiện

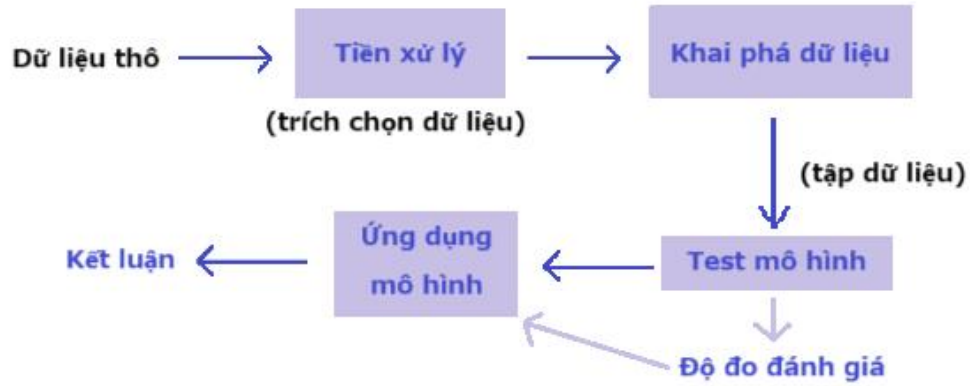

- Quy trình thực hiện khai phá bao gồm 6 bước:

  Bước 1: Thu thập tập dữ liệu đầu vào

  Bước 2: Tiền xử lý, làm sạch tập dữ liệu

  Bước 3: Chọn tác vụ khai phá dữ liệu: Phương pháp phân lớp

  Bước 4: Khai phá dữ liệu: tìm kiếm tri thức

  Bước 5: Đánh giá mẫu tìm được

  Bước 6: Biểu diễn tri thức

- Nguồn dữ liệu thô: Introducing a New Dataset of Datasets: Where, When, and How Much Data Exists on School Violence | Center For Global Development (cgdev.org)

3. Phân tích dữ liệu thô

3.1. Tổng quan

Tập dữ liệu này được xây dựng nhằm hệ thống hóa các khảo sát quốc tế đại diện cho các quốc gia có thu nhập thấp và trung bình về bạo lực học đường từ năm 2013 đến năm 2023. Bao gồm 14 khảo sát trên phạm vi quốc tế, trong đó có 10 khảo sát có câu hỏi đo lường mức độ bạo lực mà trẻ em báo cáo. Quá trình thu thập dữ liệu bao gồm phân tích các bảng câu hỏi, ghi nhận thông tin về phạm vi quốc gia, năm thực hiện, đối tượng khảo sát, loại bạo lực (vật lý, tâm lý và tình dục) và tính khả dụng của dữ liệu.

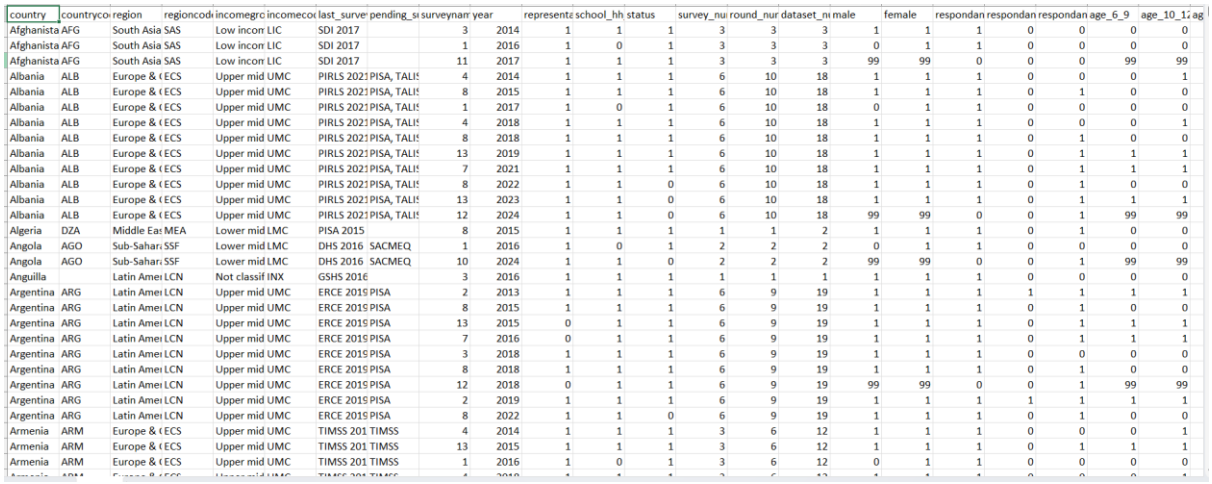

country	countryco	region	regioncod	incomegrc	incomeco	last_surve	pending_s	surveynam	year	represent	school_hh	status	survey_nu	round_nur	dataset_n	male	female	respondan	respondan	respondan	age_6_9	age_10_1	ag
Afghanista	AFG	South Asia	SAS	Low incon	LIC	SDI 2017		3	2014	1	1	1	3	3	3	1	1	1	0	0	0	0	
Afghanista	AFG	South Asia	SAS	Low incon	LIC	SDI 2017		1	2016	1	0	1	3	3	3	0	1	1	0	0	0	0	
Afghanista	AFG	South Asia	SAS	Low incon	LIC	SDI 2017		11	2017	1	1	1	3	3	3	99	99	0	0	0	99	99	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	4	2014	1	1	1	6	10	18	1	1	1	0	0	0	1	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	8	2015	1	1	1	6	10	18	1	1	1	0	1	0	0	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	1	2017	1	0	1	6	10	18	0	1	1	0	0	0	0	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	4	2018	1	1	1	6	10	18	1	1	1	0	0	0	1	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	8	2018	1	1	1	6	10	18	1	1	1	0	1	0	0	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	13	2019	1	1	1	6	10	18	1	1	1	0	1	1	1	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	7	2021	1	1	1	6	10	18	1	1	1	0	1	1	1	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	8	2022	1	1	0	6	10	18	1	1	1	0	1	0	0	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	13	2023	1	1	0	6	10	18	1	1	1	0	1	1	1	
Albania	ALB	Europe & (	ECS	Upper mid	UMC	PIRLS 2021	PISA, TALI	12	2024	1	1	0	6	10	18	99	99	0	0	1	99	99	
Algeria	DZA	Middle Eas	MEA	Lower mid	LMC	PISA 2015		8	2015	1	1	1	1	1	2	1	1	1	0	1	0	0	
Angola	AGO	Sub-Sahar	SSF	Lower mid	LMC	DHS 2016	SACMEQ	1	2016	1	0	1	2	2	2	0	1	1	0	0	0	0	
Angola	AGO	Sub-Sahar	SSF	Lower mid	LMC	DHS 2016	SACMEQ	10	2024	1	1	0	2	2	2	99	99	0	0	1	99	99	
Anguilla		Latin Amer	LCN	Not classif	INX	GSHS 2016		3	2016	1	1	1	1	1	1	1	1	1	0	0	0	0	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	2	2013	1	1	1	6	9	19	1	1	1	1	1	1	1	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	8	2015	1	1	1	6	9	19	1	1	1	0	1	0	0	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	13	2015	0	1	1	6	9	19	1	1	1	0	1	1	1	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	7	2016	0	1	1	6	9	19	1	1	1	0	1	1	1	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	3	2018	1	1	1	6	9	19	1	1	1	0	0	0	0	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	8	2018	1	1	1	6	9	19	1	1	1	0	1	0	0	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	12	2018	0	1	1	6	9	19	99	99	0	0	1	99	99	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	2	2019	1	1	1	6	9	19	1	1	1	1	1	1	1	
Argentina	ARG	Latin Amer	LCN	Upper mid	UMC	ERCE 2019	PISA	8	2022	1	1	0	6	9	19	1	1	1	0	1	0	0	
Armenia	ARM	Europe & (	ECS	Upper mid	UMC	TIMSS 201	TIMSS	4	2014	1	1	1	3	6	12	1	1	1	0	0	0	1	
Armenia	ARM	Europe & (	ECS	Upper mid	UMC	TIMSS 201	TIMSS	13	2015	1	1	1	3	6	12	1	1	1	0	1	1	1	
Armenia	ARM	Europe & (	ECS	Upper mid	UMC	TIMSS 201	TIMSS	1	2016	1	0	1	3	6	12	0	1	1	0	0	0	0	

- Dữ liệu bao gồm 1066 bản ghi và 44 thuộc tính.

3.2. Ý nghĩa các thuộc tính

STT	Thuộc tính	Ý nghĩa
1	country	Tên quốc gia hoặc khu vực
2	countrycode	Mã quốc gia gồm ba chữ cái (ISO 3166-1 alpha-3)
3	region	Tên vùng
4	regioncode	Mã vùng gồm 3 chữ cái (theo World Bank)
5	incomegroup	Nhóm thu nhập
6	incomecode	Mã nhóm thu nhập gồm 3 chữ cái (theo World Bank)
7	last_survey_year	Tên và năm của (các) cuộc khảo sát được cập nhật trên phạm vi quốc gia
8	pending_survey	Tên của (các) khảo sát đang chờ xử lý không có sẵn dữ liệu công khai
9	survey_number	Tổng số cuộc khảo sát quốc tế với các câu hỏi về bạo lực trong khoảng từ năm 2013 đến năm 2023
10	round_number	Tổng số vòng (round) khảo sát quốc tế có câu hỏi về bạo lực học đường từ năm 2013 đến năm 2023.
		Chú thích: Vòng đề cập đến những năm mà một cuộc khảo sát được thực hiện. Ví dụ, nếu khảo sát PISA được thực hiện trong 3 năm khác nhau từ năm 2013 đến năm 2023, tổng số vòng PISA sẽ là 3. Chỉ số này

		cung cấp tổng số vòng xem xét TẤT CẢ các cuộc điều tra quốc tế (chỉ số không phải là khảo sát cụ thể)
11	dataset_number	Tổng số bộ dữ liệu (dataset) của các cuộc điều tra quốc tế có câu hỏi về bạo lực học đường từ năm 2013 đến năm 2023
		Chú thích: Bộ dữ liệu đề cập đến số lượng khảo sát đã được quản lý theo thời gian và bởi người trả lời khảo sát. Ví dụ: nếu một cuộc khảo sát PISA được thực hiện trong 3 năm khác nhau và có hai người trả lời khảo sát khác nhau (tức là trẻ em và giáo viên), tổng số bộ dữ liệuPISA sẽ là 6. Chỉ số này cung cấp tổng số bộ dữ liệu xem xét TẤT CẢ các cuộc điều tra quốc tế (chỉ số này không phải là khảo sát cụ thể).
12	surveyname	Tên khảo sát
13	year	Năm thu thập dữ liệu của vòng khảo sát
14	status	Giá trị thể hiện tình trạng hoàn thành của vòng khảo sát
15	school_hh_based_survey	Giá trị thể hiện vòng khảo sát có phải là một cuộc khảo sát tại trường học hay không.
16	representativeness	Giá trị thể hiện cuộc khảo sát có đại diện cấp quốc gia hay không
17	male	Giá trị thể hiện người thực hiện cuộc khảo sát là nam
18	female	Giá trị thể hiện người thực hiện cuộc khảo sát là nữ
19	respondant_children	Giá trị thể hiện vòng khảo sát này dành cho trẻ em, thanh thiếu niên hoặc thanh niên, với câu hỏi về trải nghiệm bạo lực học đường ở trường học họ học tập
20	respondant_teacher	Giá trị thể hiện vòng khảo sát dành cho giáo viên, với câu hỏi về mức độ phổ biến của bạo lực học đường ở trường học họ giảng dạy
21	respondant_principal	Giá trị thể hiện vòng khảo sát dành cho hiệu trưởng, với câu hỏi về mức độ phổ biến của bạo lực học đường ở trường học họ quản lý
22	age_6_9	Giá trị thể hiện cuộc khảo sát được thực hiện trên đối

		tượng từ 6 đến 9 tuổi
23	age_10_12	Giá trị thể hiện cuộc khảo sát được thực hiện trên đối tượng từ 10 đến 12 tuổi
24	age_13_17	Giá trị thể hiện cuộc khảo sát được thực hiện trên đối tượng từ 13 đến 17 tuổi
25	age_18_22	Giá trị thể hiện cuộc khảo sát được thực hiện trên đối tượng từ 18 đến 22 tuổi
26	mentions_teacher	Giá trị thể hiện vòng khảo sát đề cập đến bạo lực do giáo viên gây ra
27	mentions_peer	Giá trị thể hiện bạo lực do bạn bè đồng trang lứa gây ra
28	mentions_physical	Giá trị thể hiện bạo lực học đường về mặt thể chất
29	mentions_emotional	Giá trị thể hiện bạo lực học đường về mặt tinh thần
30	mentions_sexual	Giá trị thể hiện bạo lực học đường về mặt tình dục
31	mentions_teacher_physical	Giá trị thể hiện bạo lực về mặt thể chất do giáo viên gây ra
32	mentions_teacher_emotional	Giá trị thể hiện bạo lực về mặt tinh thần do giáo viên gây ra
33	mentions_teacher_sexual	Giá trị thể hiện bạo lực về mặt tình dục do giáo viên gây ra
34	mentions_peer_physical	Giá trị thể hiện bạo lực về mặt thể chất do bạn bè đồng trang lứa gây ra
35	mentions_peer_emotional	Giá trị thể hiện bạo lực về mặt tinh thần do bạn bè đồng trang lứa gây ra
36	mentions_peer_sexual	Giá trị thể hiện bạo lực về mặt tình dục do bạn bè đồng trang lứa gây ra
37	prev_sexual_victim	Giá trị ước tính độ phổ biến của việc bạo lực tình dục có liên quan tới trường học được báo cáo bởi các nạn nhân

38	prev_sexual_staff	Giá trị ước tính độ phổ biến của việc bạo lực tình dục có liên quan tới trường học được báo cáo bởi cán bộ nhân viên nhà trường
39	prev_physical_victim	Giá trị ước tính độ phổ biến của việc bạo lực thể chất có liên quan tới trường học được báo cáo bởi các nạn nhân
40	prev_physical_staff	Giá trị ước tính độ phổ biến của việc bạo lực thể chất có liên quan tới trường học được báo cáo bởi cán bộ nhân viên nhà trường
41	prev_fight_victim	Giá trị ước tính độ phổ biến của tỷ lệ đánh nhau, gây gổ có liên quan tới trường học được báo cáo bởi các nạn nhân
42	prev_fight_staff	Giá trị ước tính độ phổ biến của tỷ lệ đánh nhau, gây gổ có liên quan tới trường học được báo cáo bởi cán bộ nhân viên nhà trường
43	prev_emo_victim	Giá trị ước tính độ phổ biến của việc bạo lực tinh thần có liên quan tới trường học được báo cáo bởi các nạn nhân
44	prev_emo_staff	Giá trị ước tính độ phổ biến của việc bạo lực tinh thần có liên quan tới trường học được báo cáo bởi cán bộ nhân viên nhà trường

PHẦN II. TIỀN XỬ LÝ DỮ LIỆU

1. Tiền xử lý dữ liệu

Là quá trình xử lý dữ liệu thô/gốc nhằm cải thiện chất lượng dữ liệu và chất lượng của kết quả khai phá.

1.1. Làm sạch dữ liệu

Là quá trình xử lý dữ liệu bị thiếu, nhận diện phần tử biên và giảm thiểu nhiễu, xử lý dữ liệu không nhất quán

1.1.1. Loại bỏ thuộc tính trùng lặp

- Đọc dữ liệu vào Weka:

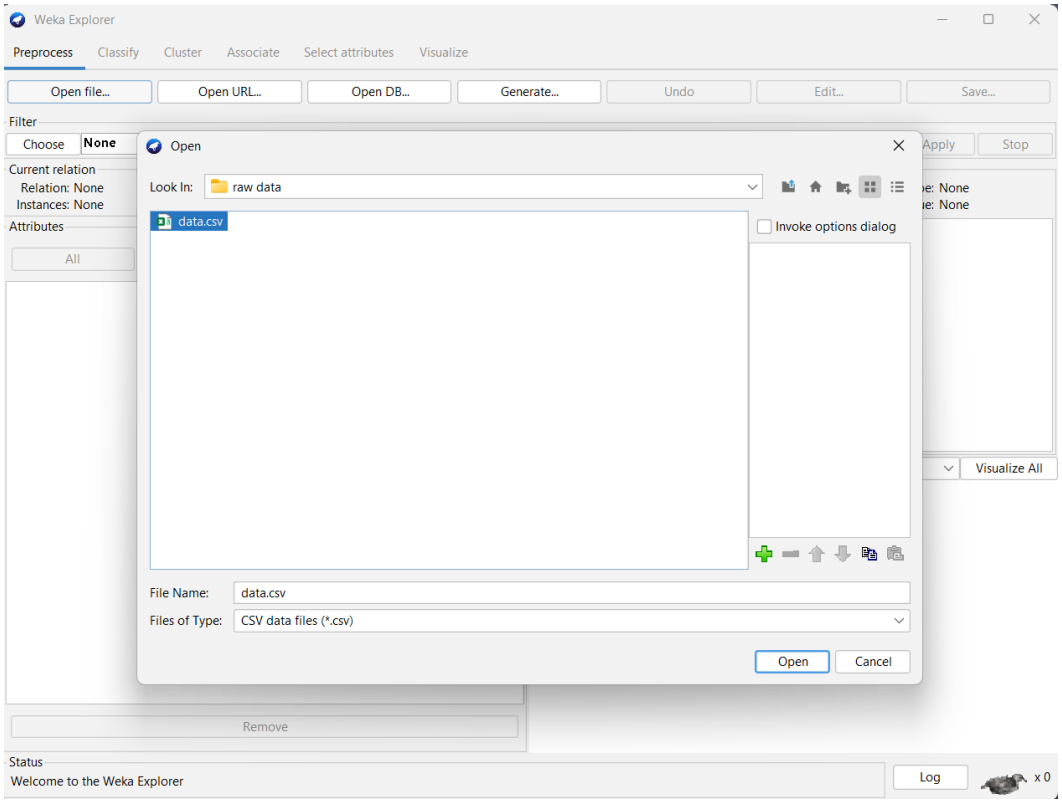

- Xét những thuộc tính dư thừa có thể suy diễn từ thuộc tính khác:

  + *country* (tên quốc gia hoặc khu vực) và *countrycode* (mã quốc gia hoặc khu vực) có cùng ý nghĩa, dựa vào *countrycode* ta có thể xác định *country* và ngược lại ⇒loại bỏ *countrycode.*

+ *region* (tên vùng) và *regioncode* (mã vùng) có cùng ý nghĩa, dựa vào *regioncode* ta có thể xác định *region* và ngược lại ⇒ loại bỏ *regioncode.*
+ *incomegroup* (nhóm thu nhập) và *incomecode* (mã nhóm thu nhập) có cùng ý nghĩa, dựa vào *incomecode* ta có thể xác định *incomegroup* và ngược lại ⇒loại bỏ *incomecode.*

⇒**Thực hiện**: Bấm chọn các ô *countrycode, regioncode, incomecode*, sau đó nhấn **Remove** để loại bỏ các thuộc tính này:

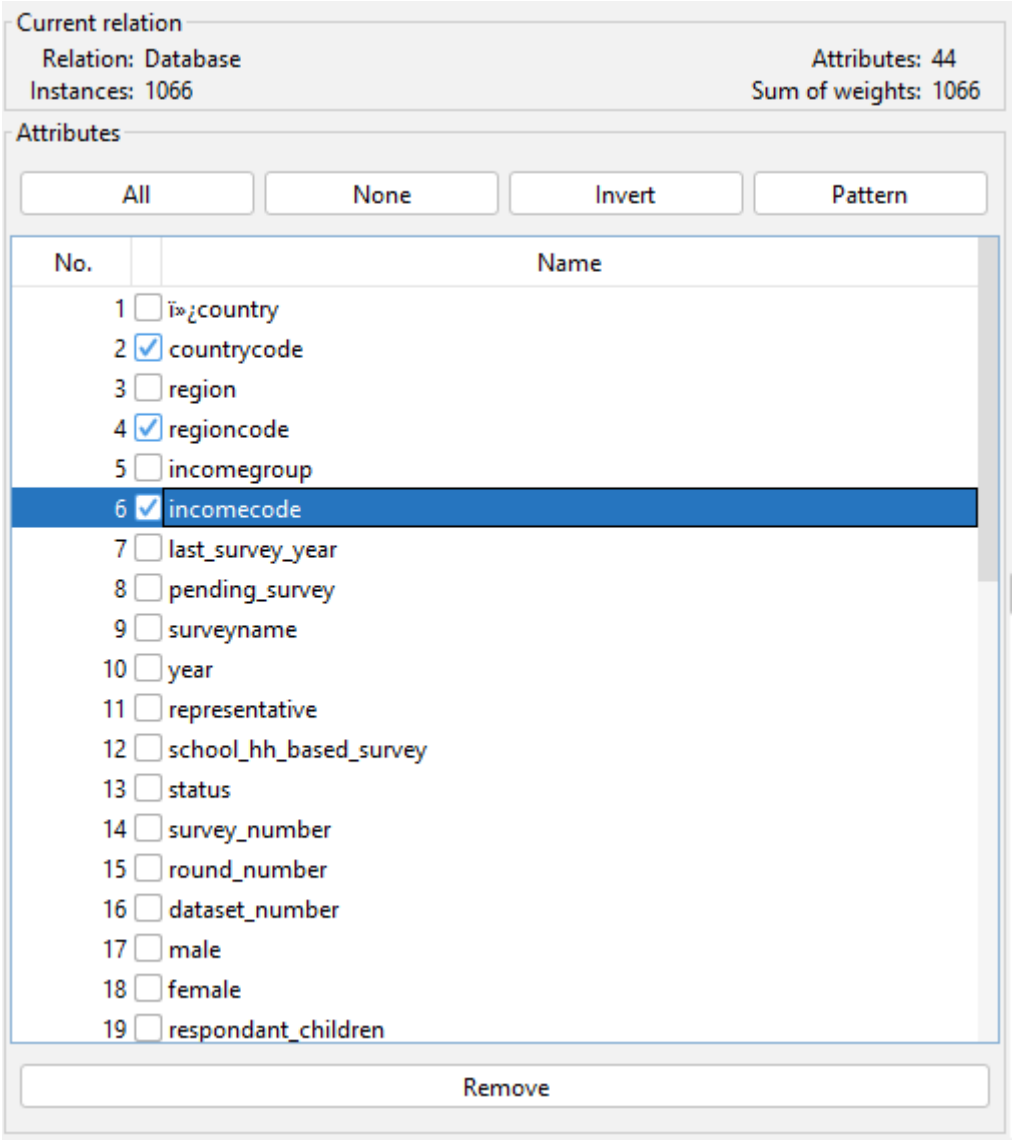

- Xét những thuộc tính dư thừa, không cần thiết:
  + *last_survey_year*
  + *pending_survey*

+ *survey_number*
+ *round_number*
+ *dataset_number*
+ *surveyname*
+ *status*
+ *school_hh_based_survey*
+ *representativeness*

Những thuộc tính trên chỉ dùng để thể hiện độ tin cậy và hiện hành của dữ liệu và không ảnh hưởng tới việc phân tích dữ liệu. Ta lược bỏ những thuộc tính này nhằm thu gọn dữ liệu.

⇒**Thực hiện**: lựa chọn các ô *last_survey_year*, *pending_survey*, *survey_number*, *round_number*, *dataset_number*, *surveyname*, *status*, *school_hh_based_survey*, *representativeness* và bấm **Remove** để loại bỏ các thuộc tính trên.

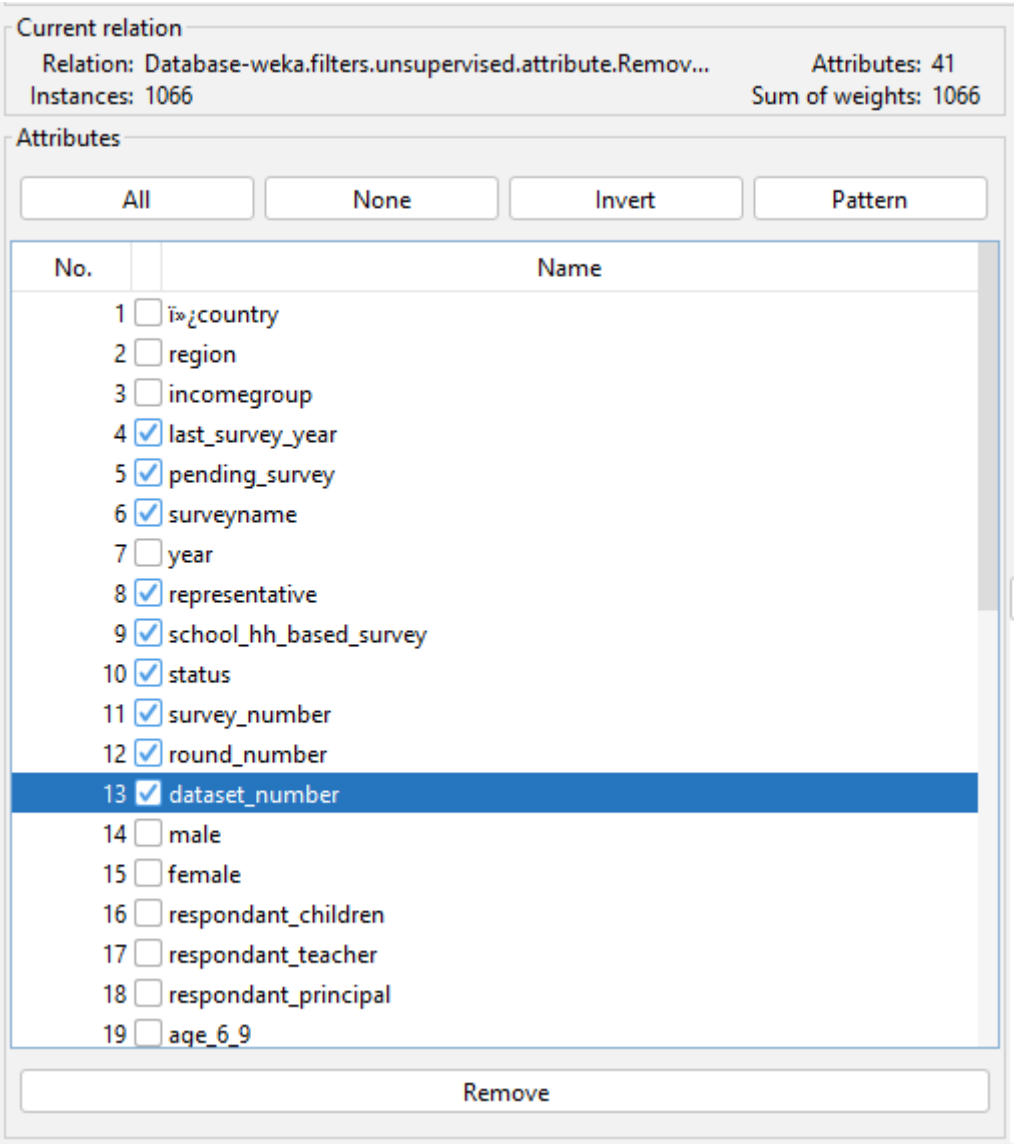

- Xét những thuộc tính dư thừa, không cần thiết đối với mục tiêu phân tích (do mục tiêu của bài toán không hướng đến từng khu vực riêng lẻ):
  + *country*
  + *region*

⇒**Thực hiện**: lựa chọn các ô *country, region* và bấm **Remove** để loại bỏ các thuộc tính trên.

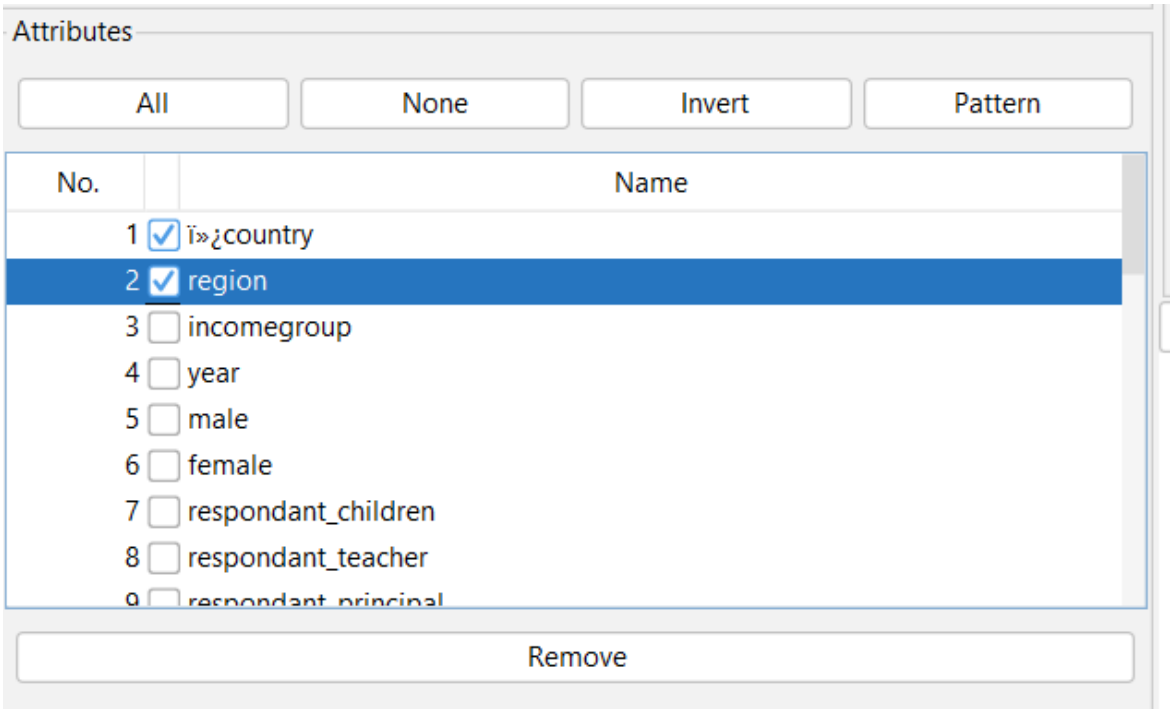

- Dữ liệu thu được sau khi loại bỏ các thuộc tính dư thừa:

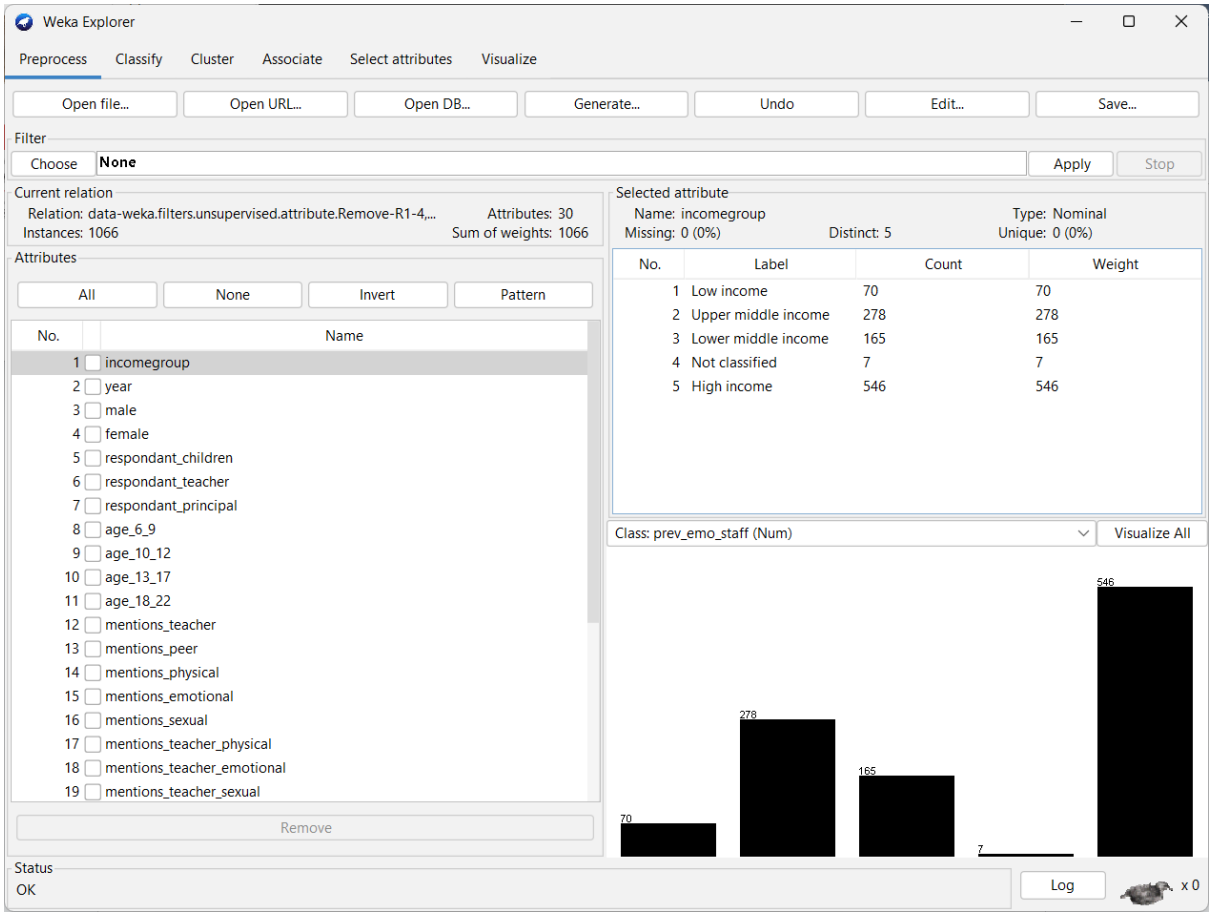

1.1.2. Xử lý nhiễu

Để thuận tiện cho việc xử lý và phân tích sau đó, ta thực hiện rời rạc hoá dữ liệu bằng cách chuyển kiểu thuộc tính về Nominal

Thực hiện:

Filter → Unsupervised → Attribute → NumericToNominal → Apply

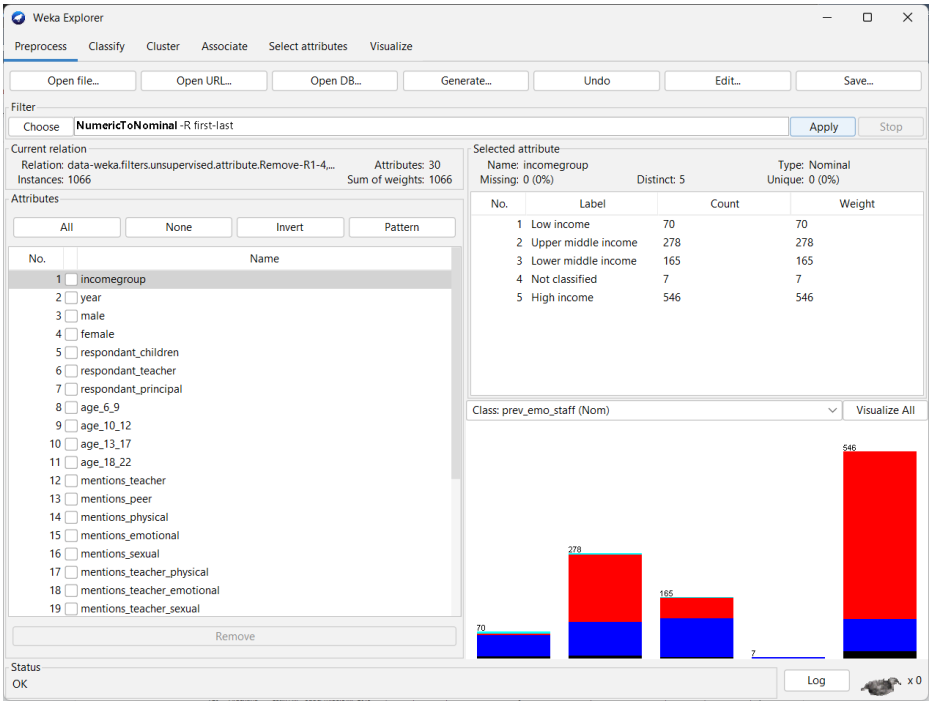

Dữ liệu sau khi chuyển về dạng Nominal:

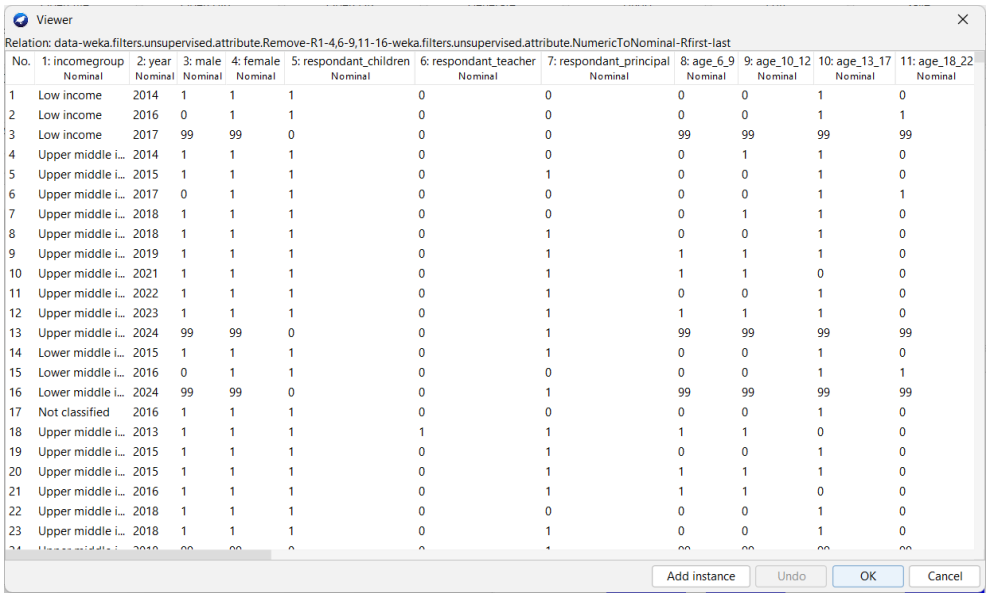

Các giá trị nhiễu gồm:

Thuộc tính	Đánh giá
year	Những giá trị "9999" là những giá trị không xác định được năm mà cuộc khảo sát được thực hiện.
age_6_9	Những giá trị "99" là những dòng không được áp dụng.
age_10_12	Những giá trị "99" là những dòng không được áp dụng.
age_13_17	Những giá trị "99" là những dòng không được áp dụng.
age_18_22	Những giá trị "99" là những dòng không được áp dụng.
mentions_teacher	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_peer	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_physical	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_emotional	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_sexual	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_teacher_physical	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)

mentions_teacher_emotional	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_teacher_sexual	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_peer_physical	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_peer_emotional	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
mentions_peer_sexual	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
prev_sexual_victim	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
prev_sexual_staff	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
prev_physical_victim	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
prev_physical_staff	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
prev_fight_victim	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)

prev_fight_staff	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
prev_emo_victim	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)
prev_emo_staff	Những giá trị "100" là những dòng cần được xác nhận (do đây là các cuộc khảo sát đang chờ xử lý mà không có bảng câu hỏi có sẵn trong các vòng khảo sát mới)

Các bước xử lý:

- Tại thuộc tính mentions_teacher: giá trị nhiễu là "100", gồm có 14 bản ghi

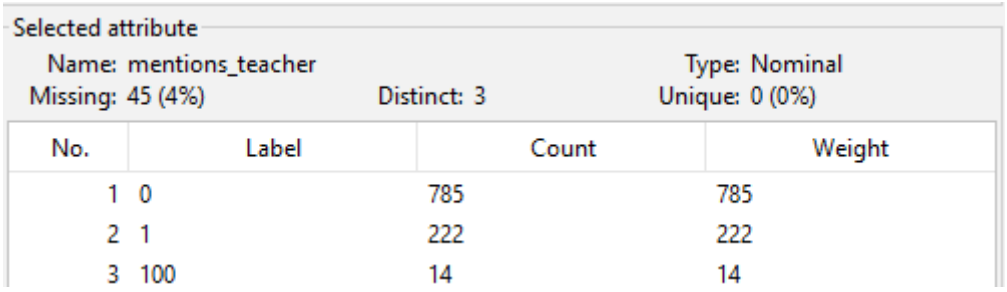
Selected attribute

Name: mentions_teacher Type: Nominal

Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	785	785
2	1	222	222
3	100	14	14

Thực hiện: loại bỏ những bản ghi có giá trị nhiễu

Filter → Unsupervised → Instance → RemoveWithValues

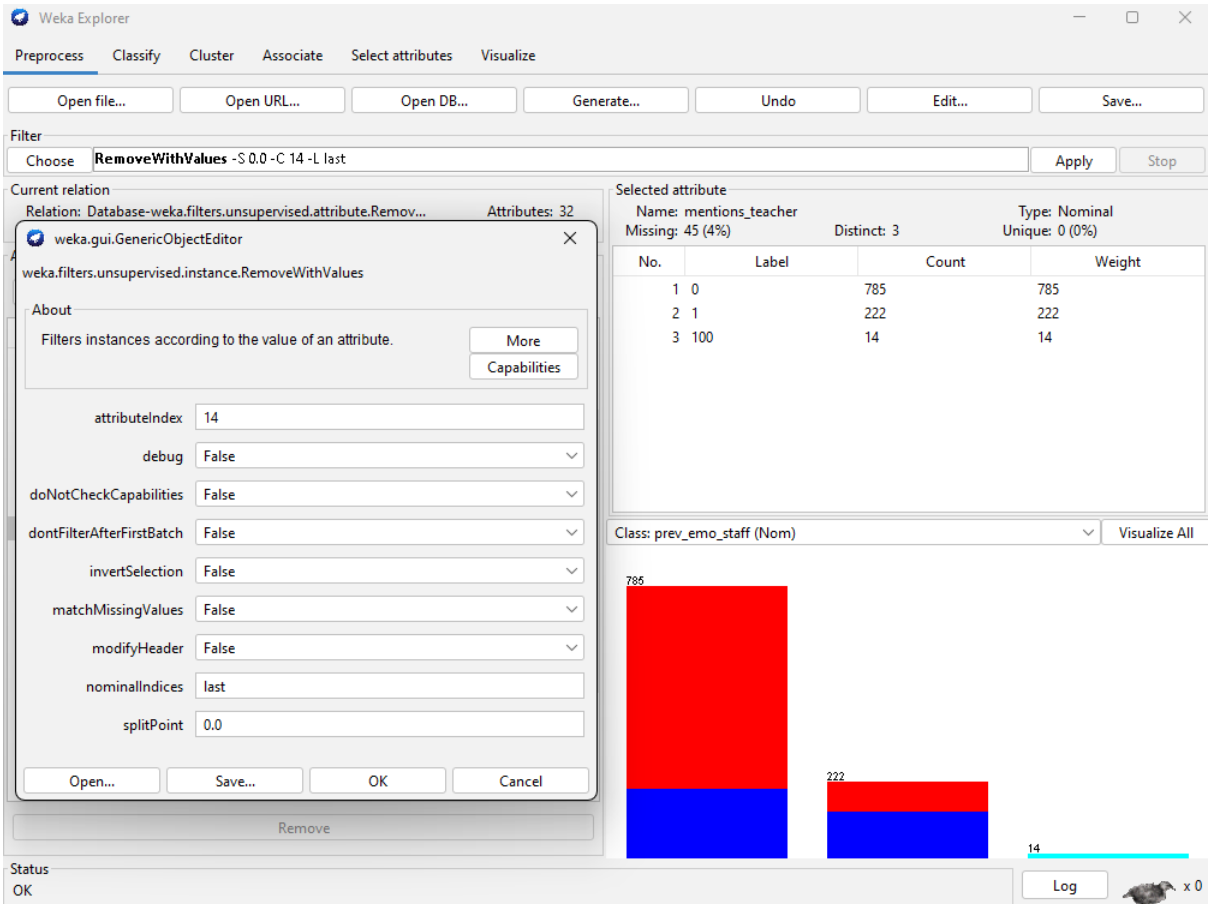

Dữ liệu tại mentions_teacher sau khi xoá:

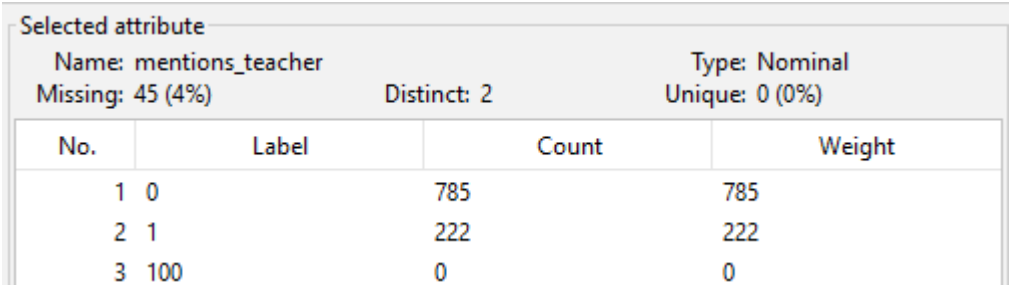

Xử lý tương tự với các thuộc tính còn lại.

- Dữ liệu tại thuộc tính *year* ban đầu: giá trị "9999" có 2 bản ghi

Selected attribute

Name: year | Type: Nominal
Missing: 45 (4%) | Distinct: 13 | Unique: 0 (0%)

No.	Label	Count	Weight
4	2016	78	78
5	2017	32	32
6	2018	200	200
7	2019	102	102
8	2020	11	11
9	2021	64	64
10	2022	87	87
11	2023	68	68
12	2024	68	68
13	9999	2	2

Dữ liệu tại thuộc tính *year* sau khi xử lý:

Selected attribute

Name: year | Type: Nominal
Missing: 45 (4%) | Distinct: 12 | Unique: 0 (0%)

No.	Label	Count	Weight
4	2016	78	78
5	2017	32	32
6	2018	200	200
7	2019	102	102
8	2020	11	11
9	2021	64	64
10	2022	87	87
11	2023	68	68
12	2024	56	56
13	9999	0	0

- Dữ liệu tại thuộc tính *male* ban đầu: giá trị "99" gồm 191 bản ghi

Selected attribute

Name: male | Type: Nominal
Missing: 45 (4%) | Distinct: 3 | Unique: 0 (0%)

No.	Label	Count	Weight
1	0	86	86
2	1	744	744
3	99	191	191

- Áp dụng RemoveWithValues:

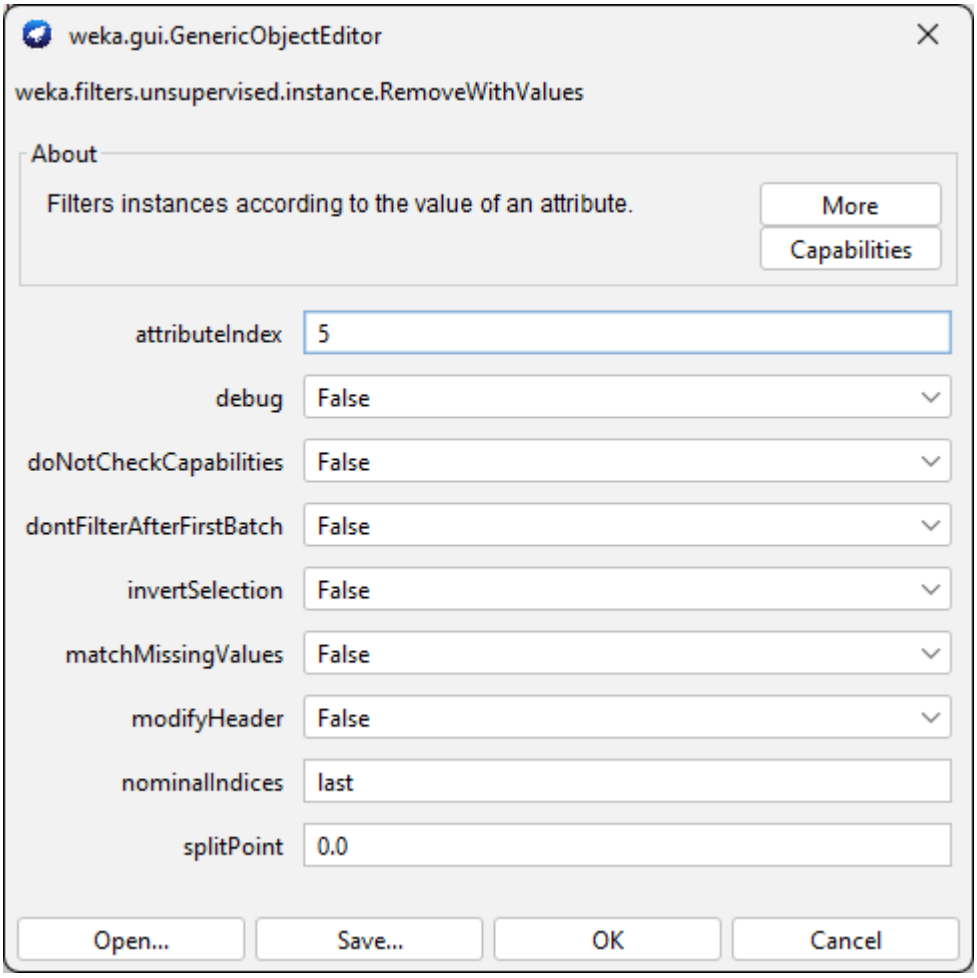

Dữ liệu tại thuộc tính *male* sau khi xử lý:

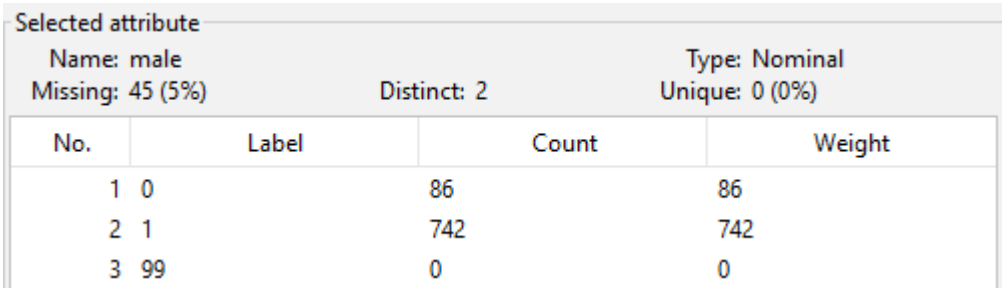

- Dữ liệu tại thuộc tính *female* ban đầu: giá trị "99" gồm 191 bản ghi

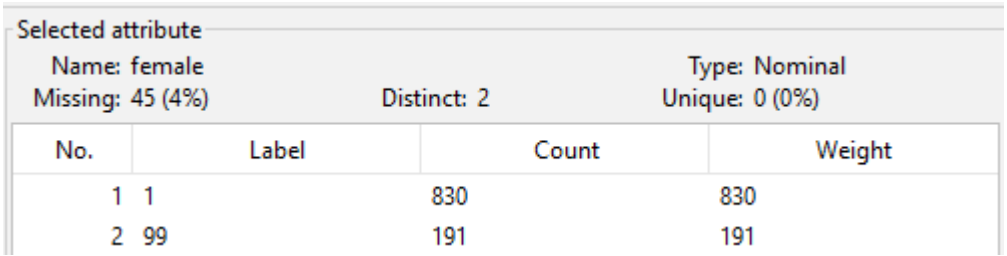

Dữ liệu tại thuộc tính *female* sau khi xử lý:

Selected attribute

Name: female Type: Nominal
Missing: 45 (5%) Distinct: 1 Unique: 0 (0%)

No.	Label	Count	Weight
1	1	828	828
2	99	0	0

- Dữ liệu tại thuộc tính *age_6_9* ban đầu:

Selected attribute

Name: age_6_9 Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	514	514
2	1	316	316
3	99	191	191

Dữ liệu tại thuộc tính *age_6_9* sau khi xử lý:

Selected attribute

Name: age_6_9 Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	512	512
2	1	316	316
3	99	0	0

- Dữ liệu tại thuộc tính *age_10_12* ban đầu:

Selected attribute

Name: age_10_12 Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	431	431
2	1	399	399
3	99	191	191

Dữ liệu tại thuộc tính *age_10_12* sau khi xử lý:

Selected attribute

Name: age_10_12 Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	429	429
2	1	399	399
3	99	0	0

- Dữ liệu tại thuộc tính *age_13_17* ban đầu:

Selected attribute

Name: age_13_17 Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	135	135
2	1	695	695
3	99	191	191

Dữ liệu tại thuộc tính *age_13_17* sau khi xử lý:

Selected attribute

Name: age_13_17 Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	135	135
2	1	693	693
3	99	0	0

- Dữ liệu tại thuộc tính *age_18_22* ban đầu:

Selected attribute

Name: age_18_22 Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	698	698
2	1	132	132
3	99	191	191

Dữ liệu tại thuộc tính *age_18_22* sau khi xử lý:

Selected attribute

Name: age_18_22 Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	698	698
2	1	130	130
3	99	0	0

- Dữ liệu tại thuộc tính *mentions_peer* ban đầu:

Selected attribute

Name: mentions_peer Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	165	165
2	1	842	842
3	100	14	14

Dữ liệu tại thuộc tính *mentions_peer* sau khi xử lý:

Selected attribute

Name: mentions_peer Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	141	141
2	1	687	687
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_physical* ban đầu:

Selected attribute

Name: mentions_physical Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	127	127
2	1	880	880
3	100	14	14

Dữ liệu tại thuộc tính *mentions_physical* sau khi xử lý:

Selected attribute

Name: mentions_physical Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	127	127
2	1	701	701
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_emotional* ban đầu:

Selected attribute

Name: mentions_emotional Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	155	155
2	1	852	852
3	100	14	14

Dữ liệu tại thuộc tính *mentions_emotional* sau khi xử lý:

Selected attribute

Name: mentions_emotional Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	131	131
2	1	697	697
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_sexual* ban đầu:

Selected attribute

Name: mentions_sexual Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	889	889
2	1	118	118
3	100	14	14

Dữ liệu tại thuộc tính *mentions_sexual* sau khi xử lý:

Selected attribute

Name: mentions_sexual Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	725	725
2	1	103	103
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_teacher_physical* ban đầu:

Selected attribute

Name: mentions_teacher_physical Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	881	881
2	1	126	126
3	100	14	14

Dữ liệu tại thuộc tính *mentions_teacher_physical* sau khi xử lý:

Selected attribute

Name: mentions_teacher_physical Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	726	726
2	1	102	102
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_teacher_emotional* ban đầu:

Selected attribute

Name: mentions_teacher_emotional Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	920	920
2	1	87	87
3	100	14	14

Dữ liệu tại thuộc tính *mentions_teacher_emotional* sau khi xử lý:

Selected attribute

Name: mentions_teacher_emotional Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	756	756
2	1	72	72
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_teacher_sexual* ban đầu:

Selected attribute

Name: mentions_teacher_sexual Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	889	889
2	1	118	118
3	100	14	14

Dữ liệu tại thuộc tính *mentions_teacher_sexual* sau khi xử lý:

Selected attribute

Name: mentions_teacher_sexual Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	725	725
2	1	103	103
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_peer_physical* ban đầu:

Selected attribute

Name: mentions_peer_physical Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	286	286
2	1	721	721
3	100	14	14

Dữ liệu tại thuộc tính *mentions_peer_physical* sau khi xử lý:

Selected attribute

Name: mentions_peer_physical Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	262	262
2	1	566	566
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_peer_emotional* ban đầu:

Selected attribute

Name: mentions_peer_emotional Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	198	198
2	1	809	809
3	100	14	14

Dữ liệu tại thuộc tính *mentions_peer_emotional* sau khi xử lý:

Selected attribute

Name: mentions_peer_emotional Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	174	174
2	1	654	654
3	100	0	0

- Dữ liệu tại thuộc tính *mentions_peer_sexual* ban đầu:

Selected attribute

Name: mentions_peer_sexual Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	950	950
2	1	57	57
3	100	14	14

Dữ liệu tại thuộc tính *mentions_peer_sexual* sau khi xử lý:

Selected attribute

Name: mentions_peer_sexual Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	786	786
2	1	42	42
3	100	0	0

- Dữ liệu tại thuộc tính *prev_sexual_victim* ban đầu:

Selected attribute

Name: prev_sexual_victim Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	904	904
2	1	103	103
3	100	14	14

Dữ liệu tại thuộc tính *prev_sexual_victim* sau khi xử lý:

Selected attribute

Name: prev_sexual_victim Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	725	725
2	1	103	103
3	100	0	0

- Dữ liệu tại thuộc tính *prev_sexual_staff* ban đầu:

Selected attribute

Name: prev_sexual_staff Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	992	992
2	1	15	15
3	100	14	14

Dữ liệu tại thuộc tính *prev_sexual_staff* sau khi xử lý:

Selected attribute

Name: prev_sexual_staff Type: Nominal
Missing: 45 (5%) Distinct: 1 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	828	828
2	1	0	0
3	100	0	0

- Dữ liệu tại thuộc tính *prev_physical_victim* ban đầu:

Selected attribute

Name: prev_physical_victim Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	271	271
2	1	736	736
3	100	14	14

Dữ liệu tại thuộc tính *prev_physical_victim* sau khi xử lý:

Selected attribute

Name: prev_physical_victim Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	92	92
2	1	736	736
3	100	0	0

- Dữ liệu tại thuộc tính *prev_physical_staff* ban đầu:

Selected attribute

Name: prev_physical_staff Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	937	937
2	1	70	70
3	100	14	14

Dữ liệu tại thuộc tính *prev_physical_staff* sau khi xử lý:

Selected attribute

Name: prev_physical_staff Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	797	797
2	1	31	31
3	100	0	0

- Dữ liệu tại thuộc tính *prev_fight_victim* ban đầu:

Selected attribute

Name: prev_fight_victim Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	857	857
2	1	150	150
3	100	14	14

Dữ liệu tại thuộc tính *prev_fight_victim* sau khi xử lý:

Selected attribute

Name: prev_fight_victim Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	678	678
2	1	150	150
3	100	0	0

- Dữ liệu tại thuộc tính *prev_fight_staff* ban đầu:

Selected attribute

Name: prev_fight_staff Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	707	707
2	1	300	300
3	100	14	14

Dữ liệu tại thuộc tính *prev_fight_staff* sau khi xử lý:

Selected attribute

Name: prev_fight_staff Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	543	543
2	1	285	285
3	100	0	0

- Dữ liệu tại thuộc tính *prev_emo_victim* ban đầu:

Selected attribute

Name: prev_emo_victim Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	310	310
2	1	697	697
3	100	14	14

Dữ liệu tại thuộc tính *prev_emo_victim* sau khi xử lý:

Selected attribute

Name: prev_emo_victim Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	131	131
2	1	697	697
3	100	0	0

- Dữ liệu tại thuộc tính *prev_emo_staff* ban đầu:

Selected attribute

Name: prev_emo_staff Type: Nominal
Missing: 45 (4%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	335	335
2	1	672	672
3	100	14	14

Dữ liệu tại thuộc tính *prev_emo_staff* sau khi xử lý:

Selected attribute

Name: prev_emo_staff Type: Nominal
Missing: 45 (5%) Distinct: 2 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	311	311
2	1	517	517
3	100	0	0

1.1.3. Xử lý dữ liệu thiếu

Có 45 bản ghi chỉ có dữ liệu ở các cột *country, countrycode, region, regioncode, incomegroup, incomecode* mà không có dữ liệu trên các cột còn lại. Điều này là do các cuộc khảo sát ở các khu vực này chưa được thực hiện hoặc chưa có dữ liệu được cập nhật.

Selected attribute

Name: year Type: Nominal
Missing: 45 (5%) Distinct: 12 Unique: 0 (0%)

Missing tại thuộc tính year

Do dữ liệu bị thiếu này chỉ chiếm một lượng không đáng kể (4%), không ảnh hưởng kết quả phân tích, ta loại bỏ những dữ liệu này.

Thực hiện:

Filter → Unsupervised → Instance → RemoveWithValues

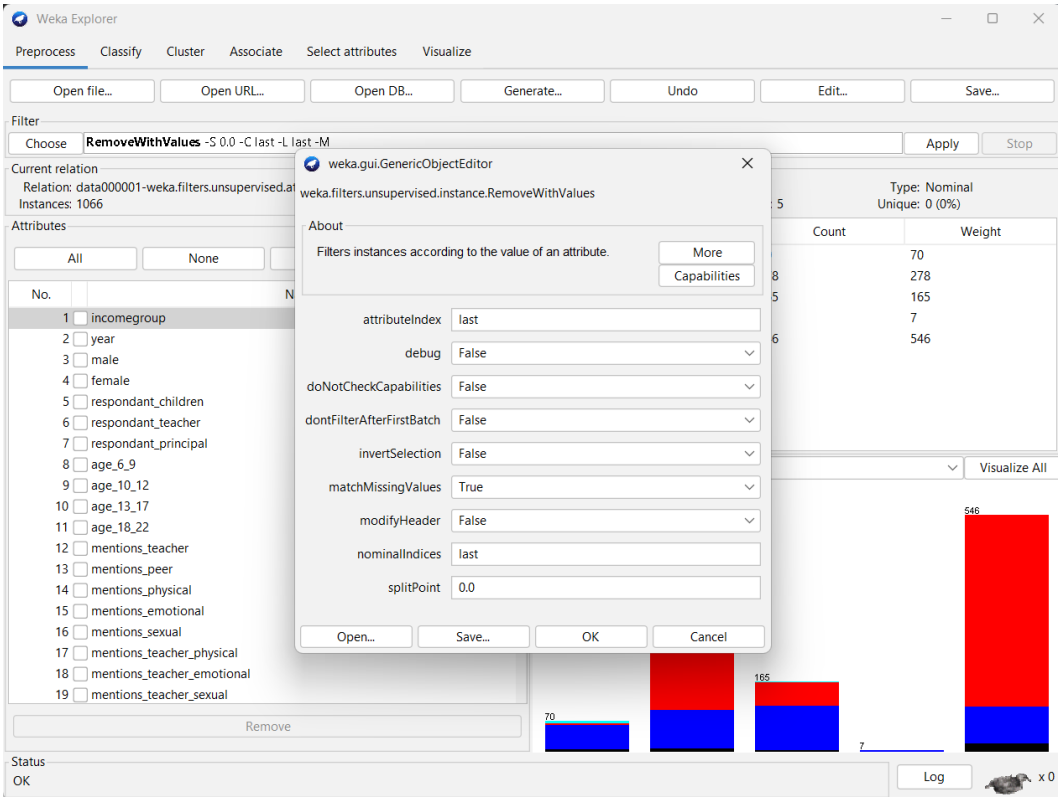

Kết quả:

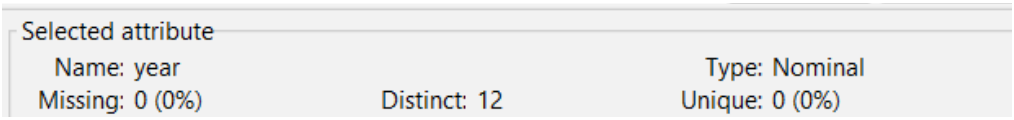

1.1.4. Xử lý dữ liệu không nhất quán

Tập dữ liệu đã nhất quán.

1.2. Tích hợp dữ liệu

Tích hợp dữ liệu là quá trình trộn dữ liệu từ các nguồn khác nhau vào một kho dữ liệu sẵn sàng cho quá trình khai phá dữ liệu.

Tích hợp dữ liệu sẽ hỗ trợ việc giảm và tránh dư thừa và không nhất quán về dữ liệu, qua đó cải thiện tính chính xác và tốc độ quá trình khai phá dữ liệu.

⇒Do dữ liệu này lấy từ một nguồn nên quy trình này bỏ qua.

2. Phân tích dữ liệu sau khi tiền xử lý lần đầu

Phân tích dữ liệu nhằm hiểu rõ hơn về dữ liệu và mối quan hệ giữa các thuộc tính do đó ta cần phân tích, nhận biết thêm về sự liên kết giữa chúng.

Dữ liệu sau khi tiền xử lý lần đầu:

Dựa vào thống kê này, ta nhận thấy có một số thuộc tính chỉ còn lại 1 giá trị sau khi thực hiện tiền xử lý. Những thuộc tính này có thể được coi là không cung cấp thông tin hữu ích cho việc phân tích và mô hình hóa do không có sự biến thiên và không thể giúp phân biệt hay đóng góp vào việc dự đoán kết quả.

Những thuộc tính đó là:

- *female*:

Selected attribute

Name: female Type: Nominal

Missing: 0 (0%) Distinct: 1 Unique: 0 (0%)

No.	Label	Count	Weight
1	1	828	828

- *respondant_children*:

Selected attribute

Name: respondant_children Type: Nominal
Missing: 0 (0%) Distinct: 1 Unique: 0 (0%)

No.	Label	Count	Weight
1	1	828	828

- *prev_sexual_staff*:

Selected attribute

Name: prev_sexual_staff Type: Nominal
Missing: 0 (0%) Distinct: 1 Unique: 0 (0%)

No.	Label	Count	Weight
1	0	828	828

2.1. Loại bỏ thuộc tính dư thừa

Sử dụng Weka loại bỏ những thuộc tính trên:

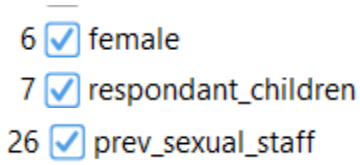

Ta nhận thấy rằng một số thuộc tính có thể được suy diễn từ thuộc tính khác:

- Những thuộc tính có thể được suy diễn từ *mentions_teacher* (do ý nghĩa của các thuộc tính này đều đề cập tới đối tượng thực hiện hành vi bạo lực là giáo viên):
  + *mentions_teacher_physical*
  + *mentions_teacher_emotional*
  + *mentions_teacher_sexual*
- Những thuộc tính có thể được suy diễn từ *mentions_peer* (do ý nghĩa của các thuộc tính này đều đề cập tới đối tượng thực hiện hành vi bạo lực là bạn bè):
  + *mentions_peer_physical*
  + *mentions_peer_emotional*
  + *mentions_peer_sexual*

- Những thuộc tính có thể được suy diễn từ *mentions_sexual* (do ý nghĩa của các thuộc tính này đều đề cập đến bạo lực liên quan tới tình dục):
  + *prev_sexual_victim*
  + *prev_sexual_staff*
- Những thuộc tính có thể được suy diễn từ *mentions_physical* (do ý nghĩa của các thuộc tính này đều đề cập đến bạo lực liên quan tới thể xác):
  + *prev_physical_victim*
  + *prev_physical_staff*
  + *prev_fight_victim*
  + *prev_fight_staff*
- Những thuộc tính có thể được suy diễn từ *mentions_emotional* (do ý nghĩa của các thuộc tính này đều đề cập đến bạo lực liên quan tới tinh thần):
  + *prev_emo_victim*
  + *prev_emo_staff*

Thực hiện loại bỏ các thuộc tính trên bằng Weka: Lựa chọn các thuộc tính tương ứng và nhấn Remove

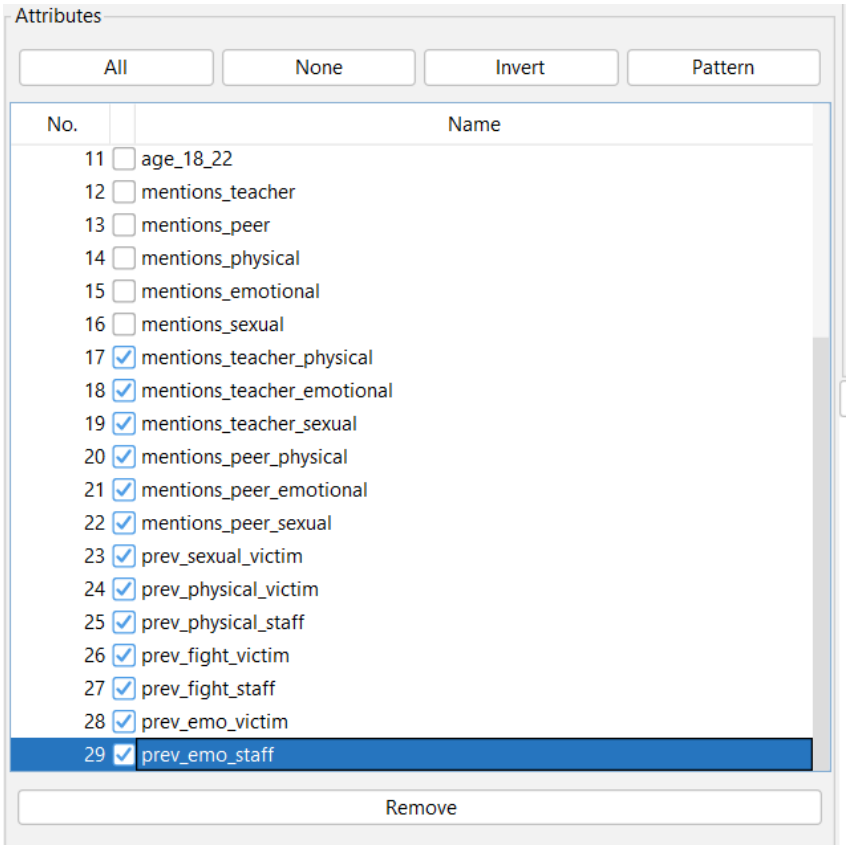

Loại bỏ những thuộc tính không ảnh hưởng tới việc phân tích (những thuộc tính này mang ý nghĩa thể hiện vai trò của người thực hiện khảo sát):

+ *respodant_teacher*
+ *respodant_principal*

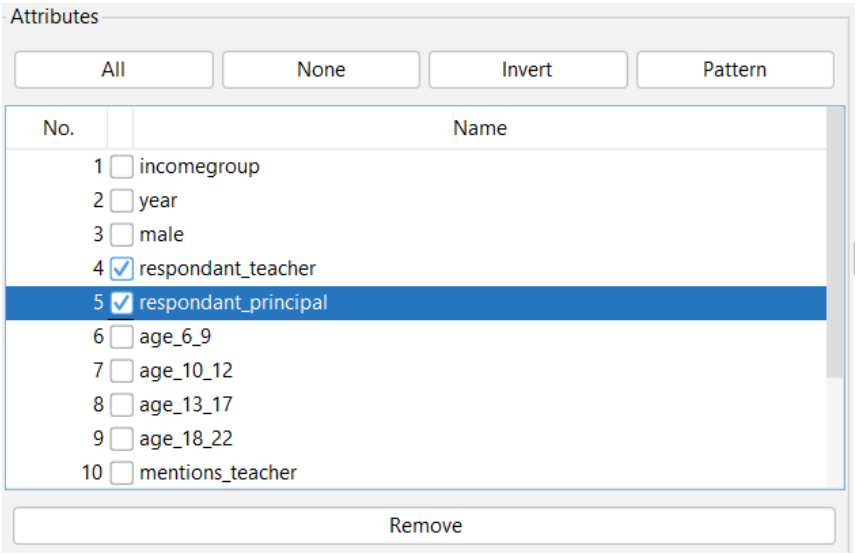

2.2. Biến đổi dữ liệu

Là quá trình biến đổi hay kết hợp dữ liệu vào những dạng thích hợp cho quá trình khai phá dữ liệu.

- Có thể thấy thuộc tính *male* có hai giá trị là 0 (=No) và 1 (=Yes). Vì thuộc tính *female* (đã được loại bỏ ở bước trước đó) có giá trị 1 (=Yes) ở tất cả bản ghi, ta có thể hiểu giá trị 0 (=No) ở *male* có nghĩa là *female*. Để tổng quát hơn, ta thực hiện đổi tên thuộc tính *male* thành *gender*, có giá trị 1 đại diện cho "male" và giá trị 0 đại diện cho "female".

Thực hiện:

- Mở giao diện Edit
- Nhấp chuột phải vào cột *male* cần đổi tên

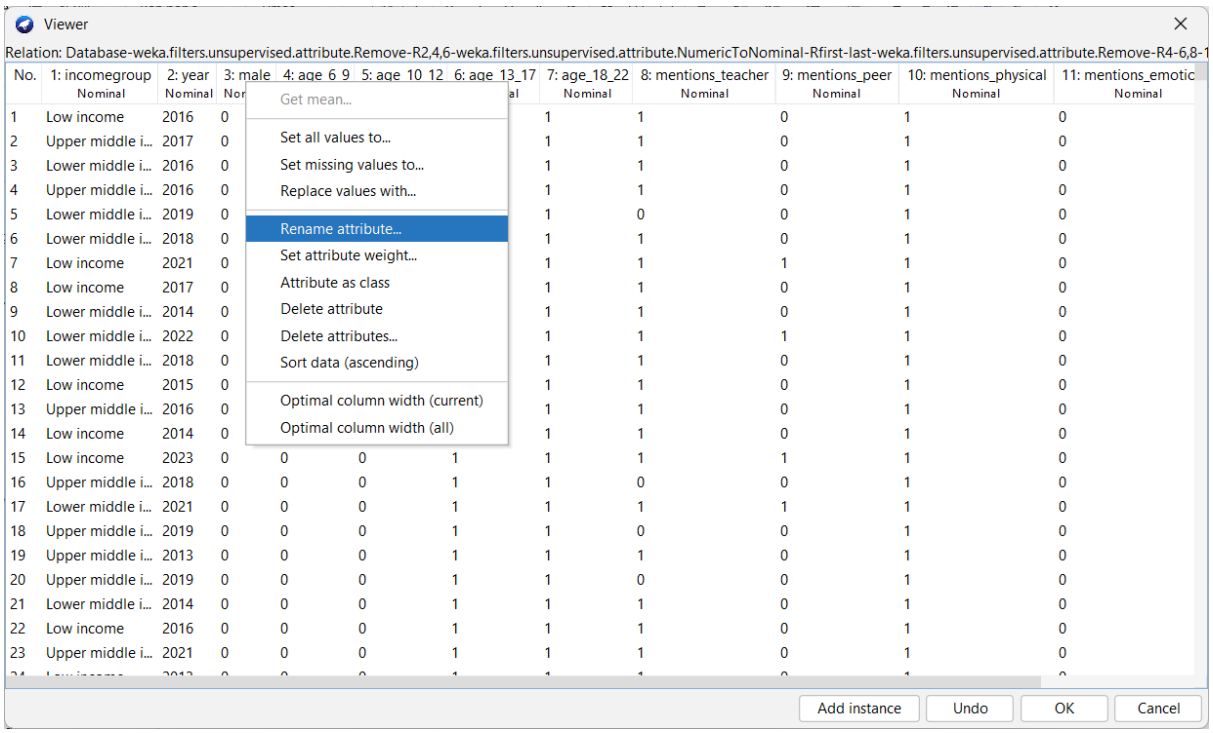

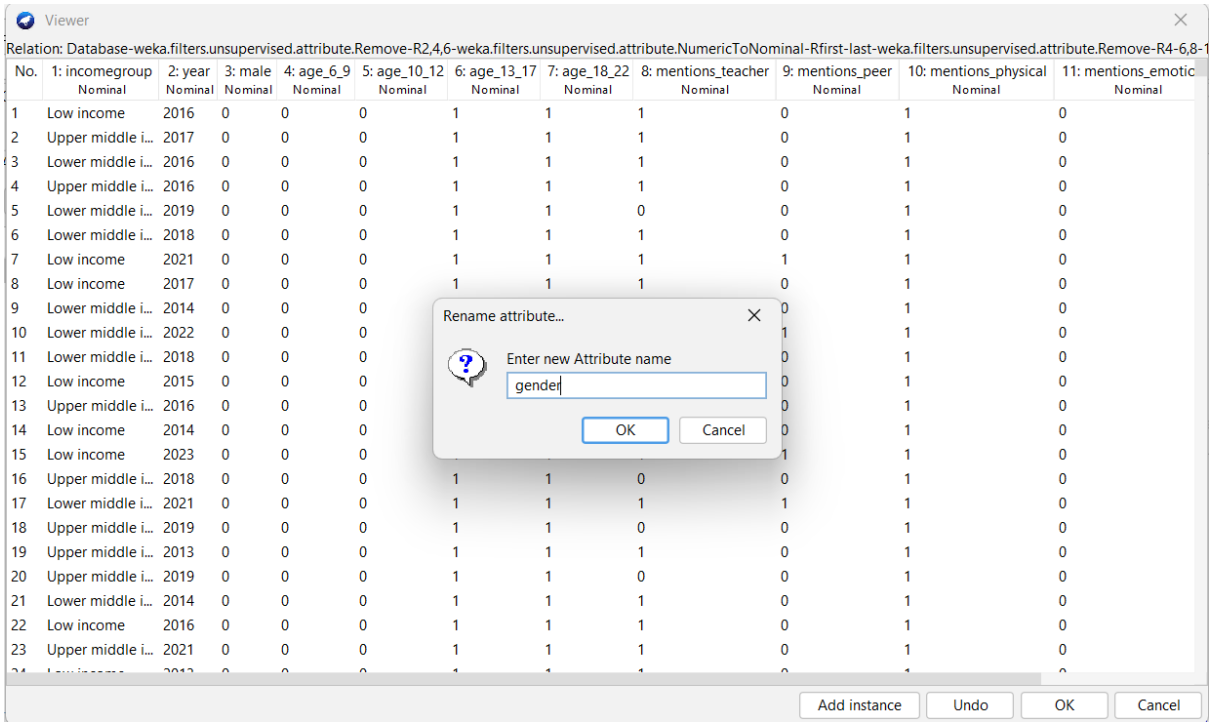

Kết quả:

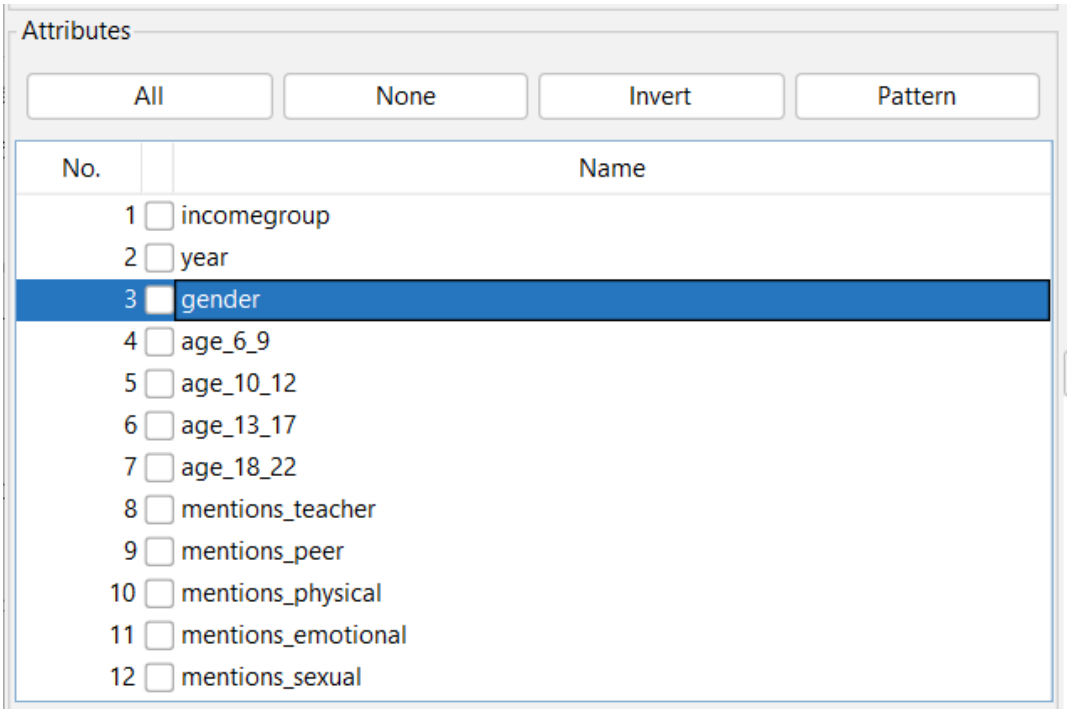

- Nhận thấy rằng các cột *age_6_9*, *age_10_12*, *age_13_17*, *age_18_22* có cùng ý nghĩa thể hiện tuổi của đối tượng được khảo sát, ta gộp các thuộc tính này thành một thuộc tính thể hiện độ tuổi: *age_group*. Với các giá trị:

Giá trị	**Ý nghĩa**

Primary School	Độ tuổi từ 6 đến 9 tuổi
Middle School	Độ tuổi từ 10 đến 12 tuổi
High School	Độ tuổi từ 13 đến 17 tuổi
University	Độ tuổi từ 18 đến 22 tuổi

Sử dụng Python:

```
def assign_age_group(row):
    age_groups = []
    if row['age_6_9'] == 1:
        age_groups.append('Primary School')
    if row['age_10_12'] == 1:
        age_groups.append('Middle School')
    if row['age_13_17'] == 1:
        age_groups.append('High School')
    if row['age_18_22'] == 1:
        age_groups.append('University')

    return ', '.join(age_groups) if age_groups else 'Unknown'
```

Kết quả:

Selected attribute

Name: age_group Type: Nominal
Missing: 0 (0%) Distinct: 5 Unique: 0 (0%)

No.	Label	Count	Weight
1	High School, University	129	129
2	High School	299	299
3	Middle School, High Sch...	83	83
4	Primary School, Middle S..	181	181
5	Primary School, Middle S..	135	135

Đồng thời thực hiện xoá những cột *age_6_9*, *age_10_12*, *age_13_17*, *age_18_22*: Chọn các thuộc tính này và Remove

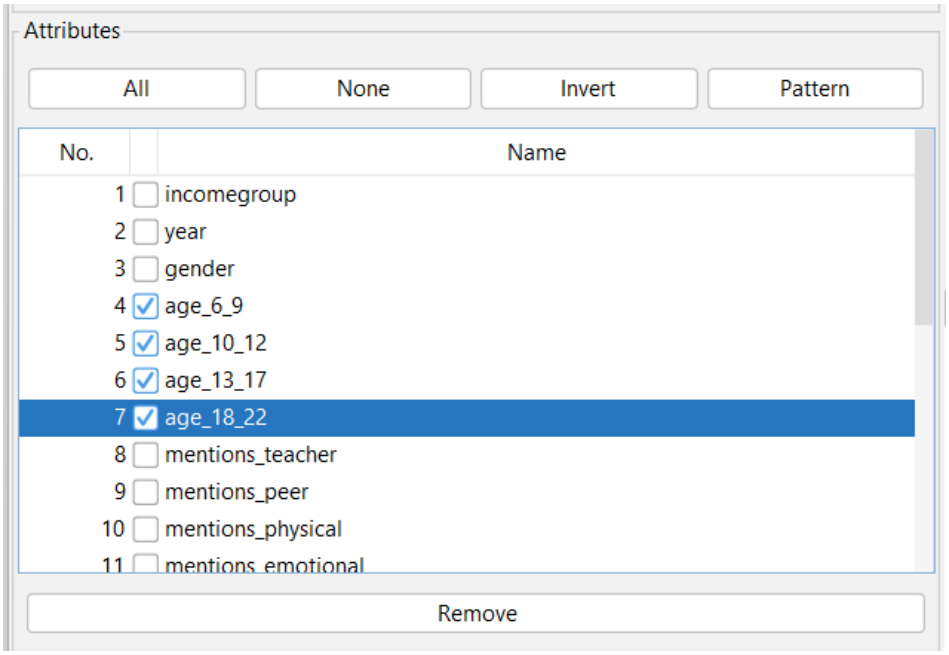

- Nhận thấy rằng các cột *mentions_physical, mentions_emotional, mentions_sexual,* có cùng ý nghĩa thể hiện về mức độ và loại bạo lực, ta gộp các thuộc tính này thành cột *violence_type* với cách thức tương tự như *age_group.*

  Kết quả:

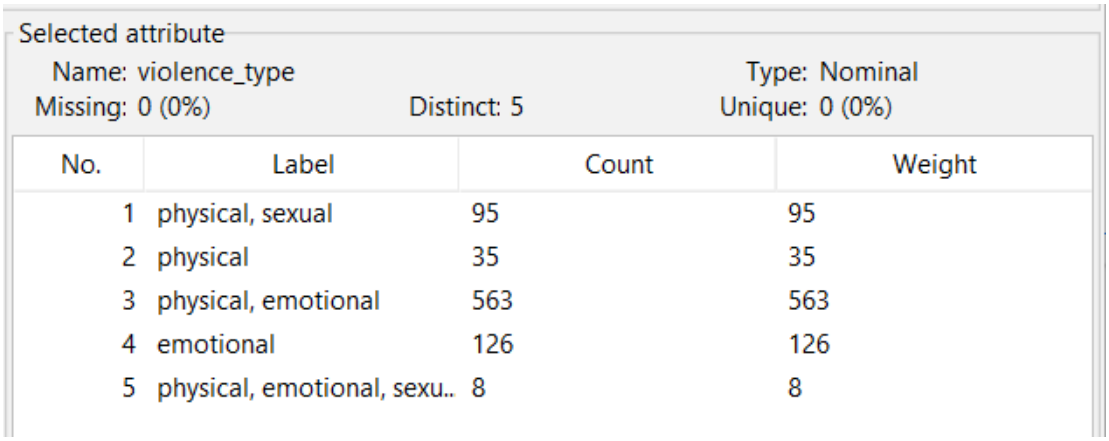

  Ý nghĩa:

Giá trị	Ý nghĩa
physical	Bị ảnh hưởng bởi bạo lực thể xác
emotional	Bị ảnh hưởng bởi bạo lực tinh thần
sexual	Bị ảnh hưởng bởi bạo lực tình dục

Xoá bỏ những thuộc tính cũ:

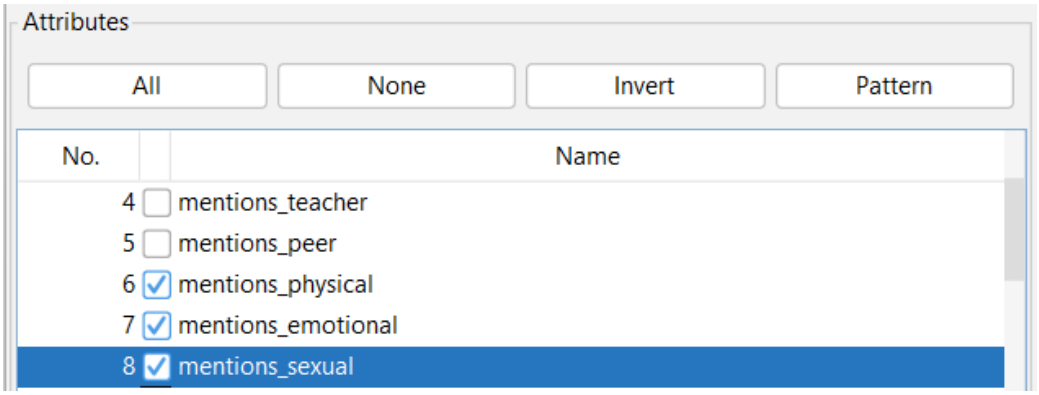

- Tương tự, cột *mentions_teacher* và *mentions_peer* có cùng ý nghĩa về đối tượng gây ra bạo lực, ta gộp giá trị của các thuộc tính này thành *bully_group.*

Kết quả:

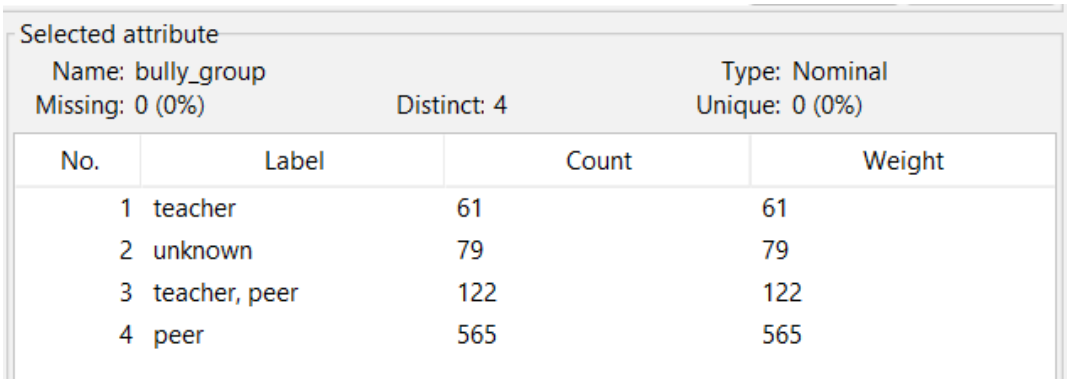

Ý nghĩa:

Giá trị	**Ý nghĩa**
teacher	Bị bạo lực bởi giáo viên
peer	Bị bạo lực bởi bạn bè cùng trang lứa
unknow	Không rõ đối tượng

Xoá những thuộc tính cũ:

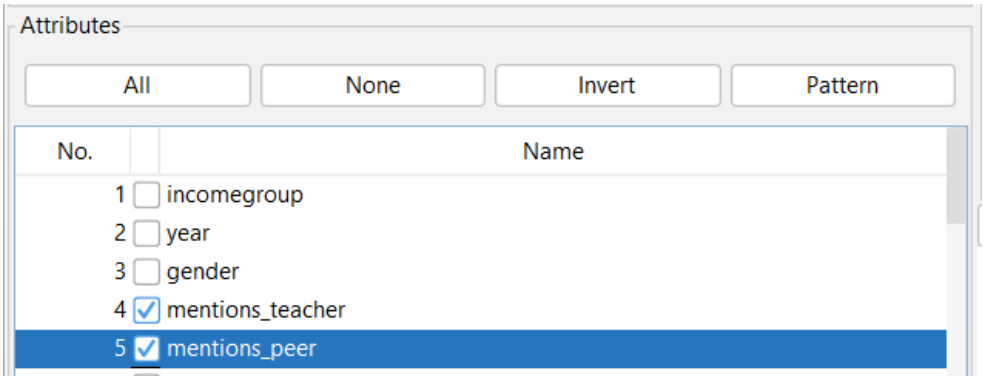

2.3. Phân tích dữ liệu sau khi tiền xử lý

Thống kê chi tiết dữ liệu:

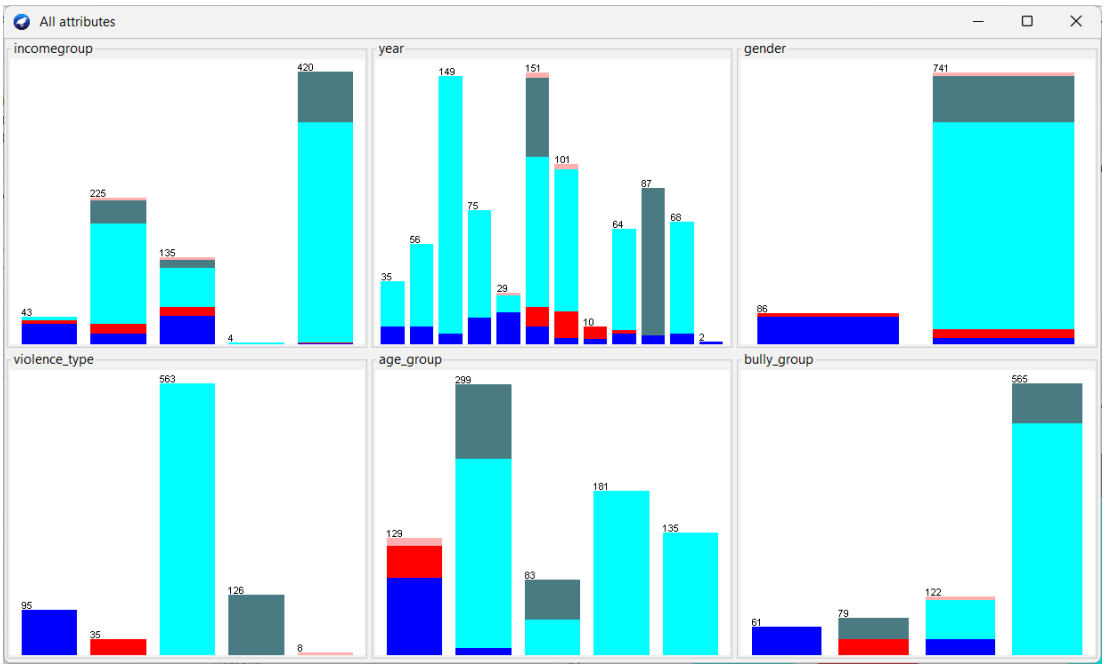

Ta nhận thấy giá trị "Not classified" (không được xếp loại) ở thuộc tính *incomegroup* chỉ có một số lượng bản ghi rất nhỏ (4 bản ghi), bên cạnh đó còn có "2024" của *year* (2 bản ghi) và "physical, emotional, sexual" của *violence_type* (8 bản ghi) trên tổng số 827 bản ghi. Những giá trị này có thể ảnh hưởng tới độ chính xác của mô hình. Ta thực hiện loại bỏ những giá trị này với filter RemoveWithValue của Weka:

Filter → Unsupervised → Instance → RemoveWithValues

Kết quả sau khi thực hiện:

- Với thuộc tính *incomegroup*:

Selected attribute

Name: incomegroup Type: Nominal
Missing: 0 (0%) Distinct: 4 Unique: 0 (0%)

No.	Label	Count	Weight
1	Low income	42	42
2	Upper middle income	222	222
3	Lower middle income	129	129
4	Not classified	0	0
5	High income	420	420

- Với thuộc tính *year:*

Selected attribute

Name: year Type: Nominal
Missing: 0 (0%) Distinct: 11 Unique: 0 (0%)

No.	Label	Count	Weight
4	2016	74	74
5	2017	27	27
6	2018	148	148
7	2019	98	98
8	2020	10	10
9	2021	64	64
10	2022	87	87
11	2023	68	68
12	2024	0	0

- Với thuộc tính *violence_type*:

Selected attribute

Name: violence_type Type: Nominal
Missing: 0 (0%) Distinct: 4 Unique: 0 (0%)

No.	Label	Count	Weight
1	physical, sexual	93	93
2	physical	35	35
3	physical, emotional	559	559
4	emotional	126	126
5	physical, emotional, sexual	0	0

2.4. Đánh giá dữ liệu

Dữ liệu đưa vào khai phá gồm **6 thuộc tính** và **813 mẫu**

STT	Thuộc tính	Ý nghĩa
1	incomegroup	Nhóm thu nhập của phạm vi đất nước hoặc khu vực thực hiện khảo sát

2	year	Năm thực hiện khảo sát
3	gender	Giới tính thực hiện khảo sát
4	age_group	Nhóm tuổi thực hiện khảo sát
5	bully_group	Đối tượng (hoặc nhóm đối tượng) thực hiện hành vi bạo lực
6	violence_type	Loại bạo lực

Dữ liệu sau khi tiền xử lý:

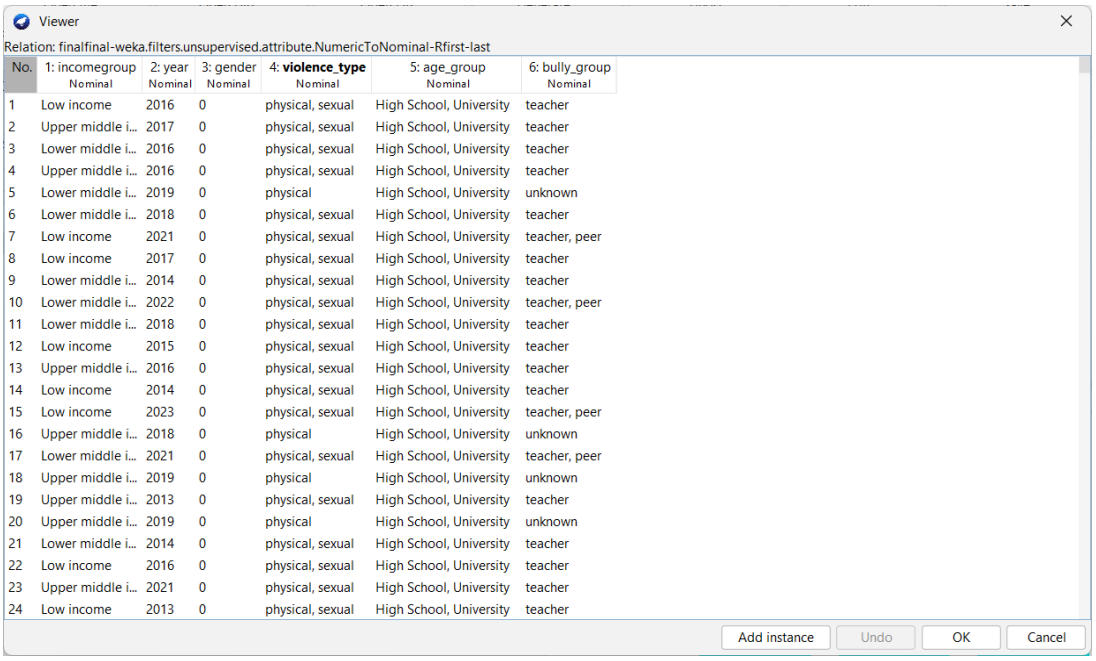

No.	1: incomegroup Nominal	2: year Nominal	3: gender Nominal	4: violence_type Nominal	5: age_group Nominal	6: bully_group Nominal
1	Low income	2016	0	physical, sexual	High School, University	teacher
2	Upper middle i...	2017	0	physical, sexual	High School, University	teacher
3	Lower middle i...	2016	0	physical, sexual	High School, University	teacher
4	Upper middle i...	2016	0	physical, sexual	High School, University	teacher
5	Lower middle i...	2019	0	physical	High School, University	unknown
6	Lower middle i...	2018	0	physical, sexual	High School, University	teacher
7	Low income	2021	0	physical, sexual	High School, University	teacher, peer
8	Low income	2017	0	physical, sexual	High School, University	teacher
9	Lower middle i...	2014	0	physical, sexual	High School, University	teacher
10	Lower middle i...	2022	0	physical, sexual	High School, University	teacher, peer
11	Lower middle i...	2018	0	physical, sexual	High School, University	teacher
12	Low income	2015	0	physical, sexual	High School, University	teacher
13	Upper middle i...	2016	0	physical, sexual	High School, University	teacher
14	Low income	2014	0	physical, sexual	High School, University	teacher
15	Low income	2023	0	physical, sexual	High School, University	teacher, peer
16	Upper middle i...	2018	0	physical	High School, University	unknown
17	Lower middle i...	2021	0	physical, sexual	High School, University	teacher, peer
18	Upper middle i...	2019	0	physical	High School, University	unknown
19	Upper middle i...	2013	0	physical, sexual	High School, University	teacher
20	Upper middle i...	2019	0	physical	High School, University	unknown
21	Lower middle i...	2014	0	physical, sexual	High School, University	teacher
22	Low income	2016	0	physical, sexual	High School, University	teacher
23	Upper middle i...	2021	0	physical, sexual	High School, University	teacher
24	Low income	2013	0	physical, sexual	High School, University	teacher

Thống kê chi tiết các thuộc tính:

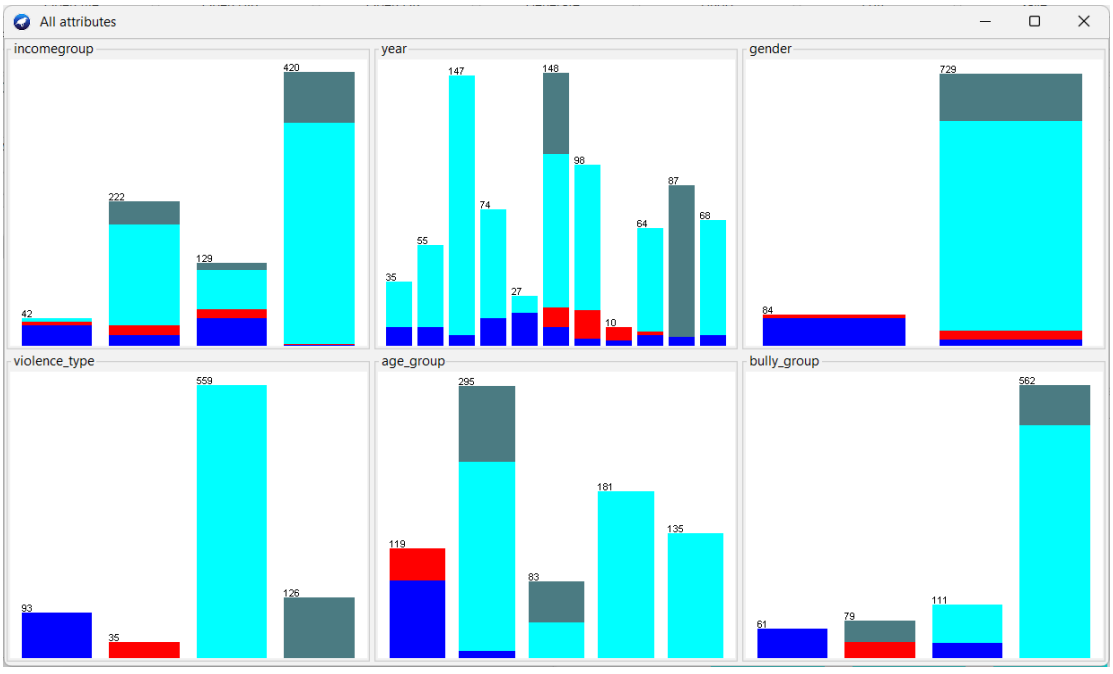

Tương quan dữ liệu giữa các thuộc tính:

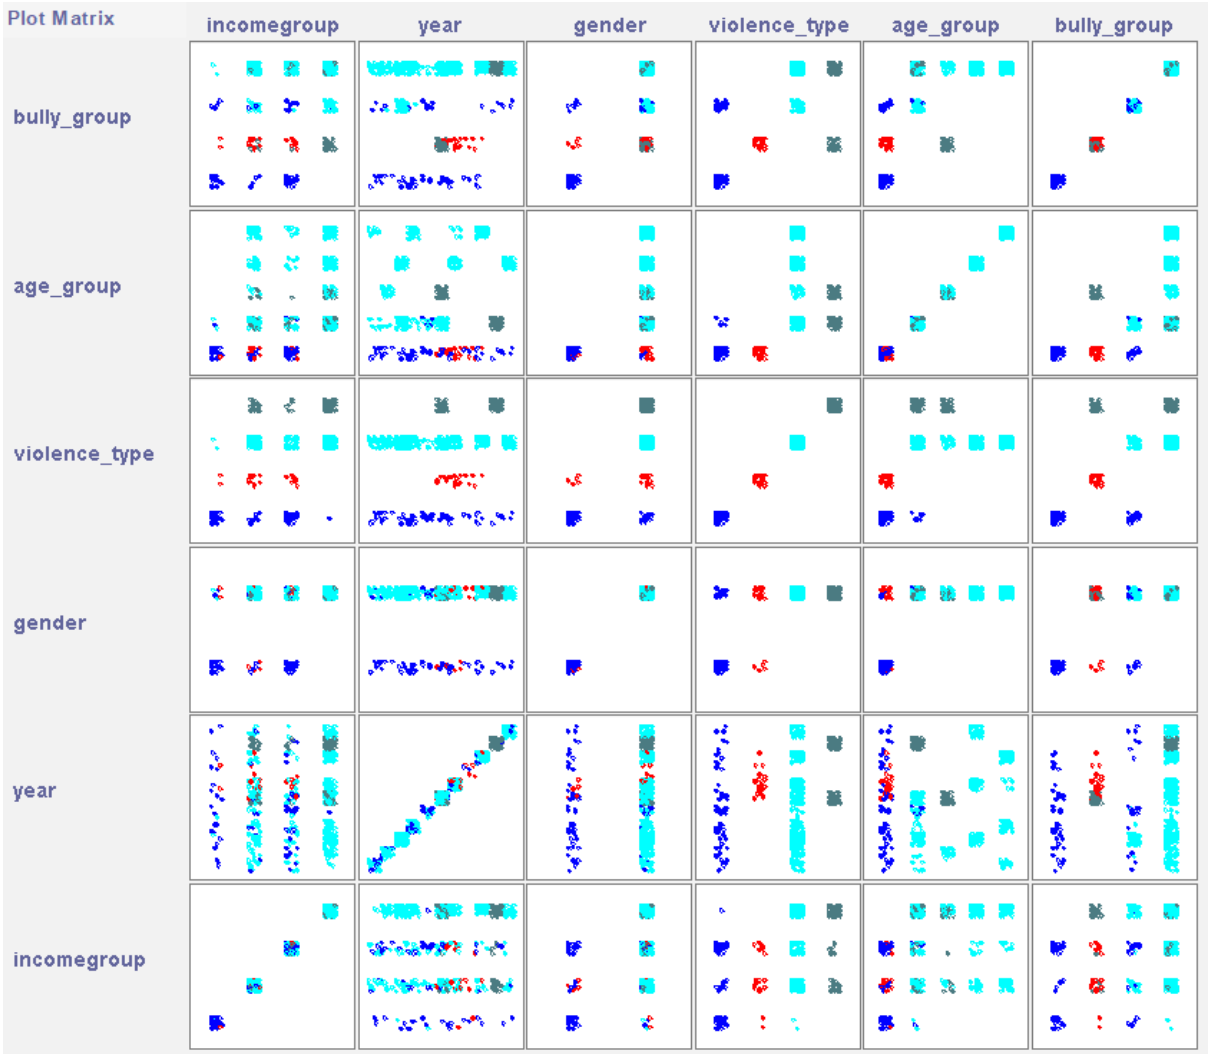

Nhận xét:

- Có sự phân tách giữa *gender* (giới tính) với *violence_type* (loại bạo lực) và *bully_group* (nhóm thực hiện bạo lực).
- *violence_type* có sự phân tách với *bully_group*, cho thấy mối liên hệ giữa loại bạo lực và các nhóm thực hiện hành vi bạo lực.
- *age_group* có mối quan hệ rõ ràng với *violence_type* và *bully_group*, cho thấy nhóm tuổi là một yếu tố quan trọng.
- *incomegroup* không có sự phân cụm rõ ràng, nhưng vẫn có một số ảnh hưởng đến các yếu tố khác.
- *year* có biến động trong *violence_type* và *bully_group*, thể hiện sự thay đổi theo thời gian.

⇒Các yếu tố như *gender, age_group* và *violence_type* có mối tương quan chặt chẽ, trong khi *incomegroup* và *year* có ảnh hưởng yếu hơn.

PHẦN III. PHÂN LỚP DỮ LIỆU

1. Phân lớp dữ liệu

Phân lớp dữ liệu là kĩ thuật dựa trên tập huấn luyện, những giá trị hay nhãn dán của lớp trong một thuộc tính phân lớp và sử dụng nó trong việc phân lớp dữ liệu mới.

Phân lớp là một hình thức học được giám sát: dữ liệu mới được phân lớp dựa trên tập huấn luyện.

Quá trình phân lớp dữ liệu gồm hai bước:

- Bước 1: Xây dựng mô hình
- Bước 2: Sử dụng mô hình

2. Phương pháp chia theo tỉ lệ

Phân chia dữ liệu huấn luyện và kiểm thử trong phân lớp giúp đánh giá hiệu suất của mô hình trên tập dữ liệu mới. Dữ liệu huấn luyện (data training) được sử dụng để huấn luyện mô hình và dữ liệu kiểm thử (data test) được sử dụng để đánh giá hiệu suất của mô hình trên tập dữ liệu mới.

Phân chia dữ liệu huấn luyện và kiểm thử cũng giúp tránh tình trạng overfitting (giảm thiểu hạn chế của ID3).

Trong phương pháp này, ta thực hiện chia dữ liệu ngẫu nhiên và phải đảm bảo ràng buộc là tỉ lệ dữ liệu của các lớp trong cả tập dữ liệu huấn luyện và kiểm thử giống nhau.

Thực hiện:

- Sử dụng Weka, ta trộn dữ liệu ngẫu nhiên:

  Filter → Unsupervised → Instance → Randomize

- Sử dụng RemovePercentage để chia tập dữ liệu huấn luyện và kiểm thử:

  Filter → Unsupervised → Instance → RemovePercentage

Ở đây ta chia tập kiểm thử là 20% và dữ liệu tập huấn luyện là 80%.

- Dữ liệu tập huấn luyện:

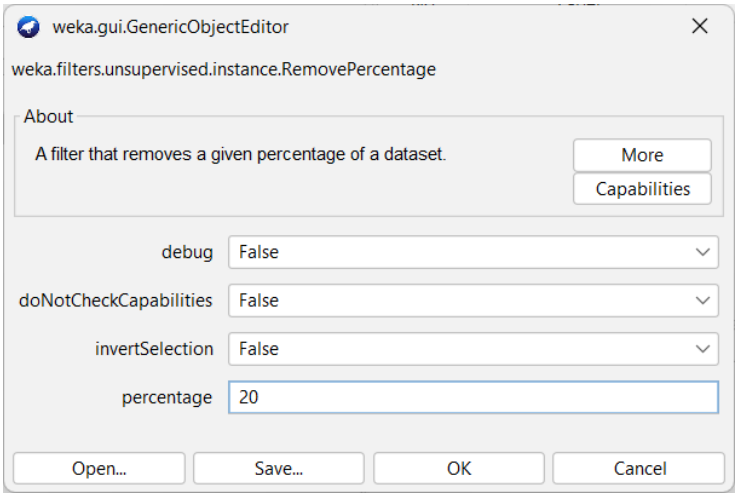

- Dữ liệu tập kiểm thử:

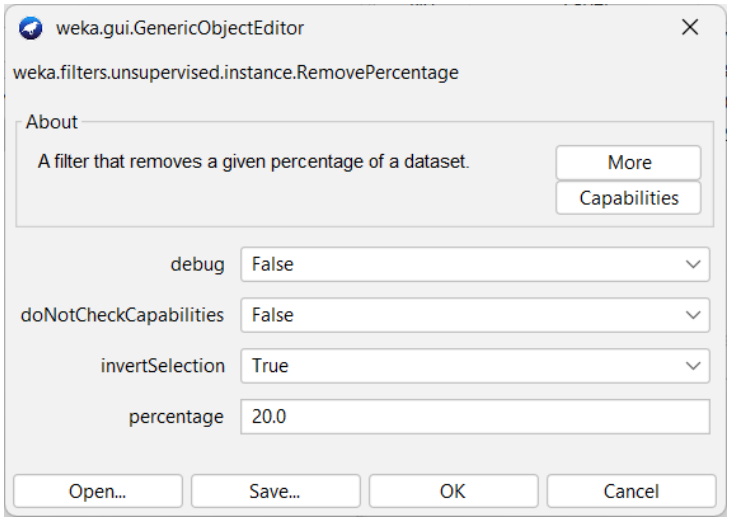

Kết quả: Sau khi chọn tỉ lệ, ta xáo trộn dữ liệu thu được tập dữ liệu huấn luyện và tập dữ liệu kiểm thử với tỉ lệ 80/20.

3. Thuật toán ID3

3.1. Lý thuyết

ID3 (Iterative Dichotomiser 3) là một thuật toán học có giám sát (supervised learning) dùng để tạo ra cây quyết định. Nó hoạt động bằng cách chọn các thuộc tính tốt nhất để phân chia dữ liệu và xây dựng cây theo các giá trị của thuộc tính đó cho đến khi đạt được lá đại diện cho lớp của dữ liệu.

Thuật toán ID3 sử dụng Entropy và độ lợi thông tin (Information Gain) để đánh giá thuộc tính nào tốt nhất để phân chia tập dữ liệu.

Hàm Entropy dùng để đo tính thuần nhất (không đồng đều) của một tập mẫu dữ liệu. Công thức Entropy cho một tập dữ liệu D là:

$$\text{Entropy}(D) = -\sum_{i=1}^{m} P_i \log_2(P_i)$$

Trong đó:

- m là số lớp trong tập dữ liệu.
- P_i là xác suất của mỗi lớp trong tập dữ liệu D.

Gain là đại lượng dùng để đo độ ưu tiên của một thuộc tính được lựa chọn cho việc phân lớp. Đại lượng này được tính thông qua hai giá trị Information và Entropy. Tại mỗi nút thuộc tính dùng để kiểm tra được chọn dựa vào lượng Information gain lớn nhất.

$$\text{Gain}(A) = \text{Entropy}(D) - \sum_{j=1}^{v} \frac{|D_j|}{|D|} \text{Entropy}(D_j)$$

Trong đó:

- D_j là các tập con được chia từ tập dữ liệu D theo các giá trị của thuộc tính A.
- v là số lượng giá trị khác nhau của thuộc tính A.

Thuộc tính có độ lợi thông tin lớn nhất sẽ được chọn để phân chia tập dữ liệu. Điều này giúp giảm độ bất định của dữ liệu và tiến gần hơn đến việc phân loại chính xác.

3.2. Quy trình thực hiện

Bước 1: Xác định thuộc tính chính để phân loại

Bước 2: Tạo một nút trên cây quyết định

Bước 3: Chia tập dữ liệu thành các tập con

Bước 4: Lặp lại các bước trên cho các tập con

Bước 5: Điều kiện dừng

- Tất cả các đối tượng trong tập con thuộc cùng một lớp.

- Không còn thuộc tính nào để chọn (tức là các thuộc tính đã được sử dụng hết).
- Tập dữ liệu quá nhỏ để tiếp tục phân chia.

Bước 6: Gắn nhãn cây với lớp được phổ biến nhất của các đối tượng trong tập dữ liệu đã xét

3.3. Giải thích các thống kê và độ đo theo lớp

3.3.1. Các thống kê

- ***Correctly Classified Instances:*** Số lượng các mẫu trong tập dữ liệu được phân loại chính xác bởi mô hình
- ***Incorrectly Classified Instances:*** Số lượng các mẫu trong tập dữ liệu bị phân loại sai bởi mô hình
- ***Kappa statistic*** (Thống kê Kappa): Đây là một chỉ số đo lường sự đồng ý giữa nhãn lớp được dự đoán và thực tế, cho biết rằng mô hình này dự đoán rất hiệu quả so với một mô hình dự đoán ngẫu nhiên hay không
- ***Mean absolute error*** (Sai số trung bình tuyệt đối): Sai số trung bình giữa xác suất dự đoán của mô hình và xác suất thực tế tương ứng với mỗi mẫu
- ***Root mean squared error*** (Căn bậc hai của sai số trung bình bình phương): là căn bậc hai của sai số trung bình bình phương giữa xác suất dự đoán của mô hình và xác suất thực tế tương ứng với mỗi mẫu
- ***Relative absolute error*** (Sai số tuyệt đối tương đối): Đây là sai số trung bình giữa xác suất dự đoán của mô hình và xác suất thực tế, được chuẩn hóa bởi xác suất thực tế trung bình.
- ***Root relative squared error*** (Căn bậc hai của sai số bình phương tương đối): Đây là căn bậc hai của sai số trung bình bình phương giữa xác suất dự đoán của mô hình và xác suất thực tế, được chuẩn hóa bởi xác suất thực tế trung bình
- ***Total Number of Instances***: Tổng số lượng mẫu trong tập dữ liệu

3.3.2. Các độ đo theo lớp

- ***TP Rate:*** Tỷ lệ số lượng các mẫu được phân loại chính xác vào nhãn Positive (dương tính) so với tổng số mẫu Positive trong tập dữ liệu
- ***FP Rate***: Tỷ lệ số lượng các mẫu bị phân loại sai vào nhãn Positive so với tổng số mẫu Negative trong tập dữ liệu.

- ***Precision***: Tỷ lệ số lượng các mẫu được phân loại chính xác vào nhãn Positive so với tổng số các mẫu được phân loại vào nhãn Positive.
- ***Recall***: Tỷ lệ số lượng các mẫu được phân loại chính xác vào nhãn Positive so với tổng số mẫu Positive trong tập dữ liệu.
- ***F-Measure***: Kết hợp giữa Precision và Recall để đánh giá hiệu quả phân loại. F-Measure càng lớn thì phân loại càng chính xác.
- ***MCC***: Độ đo tính tương đồng của hai chuỗi số. MCC = 1 tương đương với việc phân loại hoàn hảo và MCC = -1 tương đương với việc phân loại hoàn toàn ngược lại.
- ***ROC Area:*** Đường cong ROC được sử dụng để đánh giá hiệu quả của thuật toán phân loại trong bài toán dự đoán nhị phân. ROC Area là diện tích dưới đường cong ROC.
- ***PRC Area:*** Đường cong Precision-Recall được sử dụng để đánh giá hiệu quả của thuật toán phân loại trong bài toán dự đoán nhị phân. PRC Area là diện tích dưới đường cong Precision-Recall

3.4. Kết quả, nhận xét

3.4.1. Use training test

Sử dụng chính tập dữ liệu huấn luyện để kiểm nghiệm

3.4.1.1. Kết quả thu được

```
Correctly Classified Instances         649               99.8462 %
Incorrectly Classified Instances         1                0.1538 %
Kappa statistic                          0.9969
Mean absolute error                      0.0014
Root mean squared error                  0.0261
Relative absolute error                  0.5548 %
Root relative squared error              7.4607 %
Total Number of Instances              650

=== Detailed Accuracy By Class ===

                 TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
                 1,000    0,002    0,988      1,000    0,994      0,993    1,000     0,999     physical, sexual
                 1,000    0,000    1,000      1,000    1,000      1,000    1,000     1,000     physical
                 0,998    0,000    1,000      0,998    0,999      0,996    1,000     1,000     physical, emotional
                 1,000    0,000    1,000      1,000    1,000      1,000    1,000     1,000     emotional
Weighted Avg.    0,998    0,000    0,998      0,998    0,998      0,997    1,000     1,000

=== Confusion Matrix ===

   a   b   c   d   <-- classified as
  80   0   0   0 |   a = physical, sexual
   0  26   0   0 |   b = physical
   1   0 444   0 |   c = physical, emotional
   0   0   0  99 |   d = emotional
```

3.4.1.2. Nhận xét

- Thống kê:

  + Correctly Classified Instances: Độ chính xác rất cao, 99.85%
  + Incorrectly Classified Instances: Chỉ có 1 mẫu bị phân loại sai, chiếm 0.1538%
  + Kappa statistic (Thống kê Kappa): Đạt 0.9969, cho thấy sự phù hợp cao giữa dự đoán của mô hình và kết quả thực tế.
  + Mean absolute error (Sai số trung bình tuyệt đối): 0.0014, cho thấy sự khác biệt trung bình giữa dự đoán và giá trị thực là rất nhỏ
  + Root mean squared error (Căn bậc hai của sai số trung bình bình phương): 0.0261, một sai số bình phương trung bình căn bậc hai rất thấp, cho thấy mức độ chính xác rất cao.
  + Relative absolute error (Sai số tuyệt đối tương đối): 0.5548%, tỷ lệ sai số tương đối so với sai số dự đoán trong tập dữ liệu là cực kỳ nhỏ.
  + Root relative squared error (Căn bậc hai của sai số bình phương tương đối): 7.4607%, con số này cũng rất thấp, chỉ ra rằng mô hình dự đoán chính xác cao.
- Chi tiết theo lớp:
  + TP Rate: Tất cả các lớp đều có tỷ lệ TP rất cao (0.998 đến 1.000), điều này chỉ ra rằng mô hình nhận dạng rất tốt các mẫu thuộc từng lớp cụ thể.
  + FP Rate: Rất thấp (từ 0.000 đến 0.002), tức là mô hình hiếm khi phân loại nhầm giữa các lớp.
  + Precision: Tất cả các lớp có độ chính xác từ 0.988 đến 1.000, điều này cho thấy mô hình rất ít khi dự đoán sai khi đưa ra kết quả dương tính.
  + Recall: Đều ở mức cao (từ 0.998 đến 1.000), tức là mô hình gần như không bỏ sót các trường hợp cần phát hiện.
  + F-Measure: Giá trị F-Measure cao (từ 0.994 đến 1.000) cho thấy sự cân bằng tốt giữa precision và recall cho từng lớp.
  + MCC: Từ 0.993 đến 1.000, chỉ ra rằng mô hình có hiệu quả cao trong việc phân loại.
- Ma trận nhầm lẫn: Hầu hết các mẫu đều được phân loại chính xác theo từng lớp. Duy nhất có một lỗi phân loại giữa lớp "physical" (bạo lực vật lý) và "physical, emotional" (bạo lực vật lý, cảm xúc), điều này có thể là do hai lớp này có đặc điểm tương đồng.

3.4.2. Cross-validation

Chia dữ liệu thành nhiều phần (Folds) để thực hiện nhiều lần đánh giá kết quả.

3.4.2.1. Kết quả thu được

```
Correctly Classified Instances         647               99.5385 %
Incorrectly Classified Instances         3                0.4615 %
Kappa statistic                          0.9906
Mean absolute error                      0.0029
Root mean squared error                  0.0447
Relative absolute error                  1.1774 %
Root relative squared error             12.7548 %
Total Number of Instances              650

=== Detailed Accuracy By Class ===

                 TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
                 0,975    0,002    0,987      0,975    0,981      0,979    0,993     0,975     physical, sexual
                 1,000    0,000    1,000      1,000    1,000      1,000    1,000     1,000     physical
                 0,998    0,010    0,996      0,998    0,997      0,989    0,996     0,997     physical, emotional
                 1,000    0,000    1,000      1,000    1,000      1,000    1,000     1,000     emotional
Weighted Avg.    0,995    0,007    0,995      0,995    0,995      0,990    0,997     0,995

=== Confusion Matrix ===

   a   b   c   d   <-- classified as
  78   0   2   0 |   a = physical, sexual
   0  26   0   0 |   b = physical
   1   0 444   0 |   c = physical, emotional
   0   0   0  99 |   d = emotional
```

3.4.2.2. Nhận xét

- Theo thống kê:
  - + Correctly Classified Instances: mô hình cho ra độ chính xác cao: 99,54%
  - + Incorrectly Classified Instances: Chỉ có 3 mẫu bị phân loại sai
  - + Kappa statistic (Thống kê Kappa): Chỉ số Kappa rất cao là 0,9906 cho thấy sự hiệu quả với mô hình dự đoán ngẫu nhiên
  - + Mean absolute error (Sai số trung bình tuyệt đối): 0.0029, cho thấy sự khác biệt trung bình giữa dự đoán và giá trị thực là rất nhỏ
  - + Root mean squared error (Căn bậc hai của sai số trung bình bình phương) là 0.0447, thể hiện độ lệch bình phương giữa dự đoán và thực tế cũng khá thấp.
  - + Relative absolute error (Sai số tuyệt đối tương đối): 1.1774%, thể hiện sai số thấp giữa xác suất dự đoán của mô hình và thực tế
  - + Root relative squared error (Căn bậc hai của sai số bình phương tương đối): 12.7584%, mô hình hoạt động ổn định
- Độ đo theo lớp:

+ Lớp "physical, sexual": Tỷ lệ dự đoán đúng (TP Rate) là 0.975, Precision là 0.987, Recall là 0.975 và F-Measure là 0.981, cho thấy mô hình chạy rất tốt với lớp này.
+ Lớp "physical": Tỷ lệ TP, Precision, Recall và F-Measure đều là 1.000, cho thấy mô hình không có lỗi phân loại nào trong lớp này.
+ Lớp "physical, emotional": Tỷ lệ TP là 0.998, Precision là 0.996, Recall là 0.998, và F-Measure là 0.997, thể hiện độ chính xác gần như 100%.
+ Lớp "emotional": Mọi chỉ số đều đạt 1.000, cho thấy mô hình phân loại tuyệt đối chính xác cho lớp này

- Ma trận nhầm lẫn (Confusion Matrix): Ma trận cho thấy một số ít nhầm lẫn giữa các lớp "physical, sexual" và "physical, emotional", với 2 mẫu bị phân loại sai từ lớp "physical, sexual" sang lớp "physical, emotional". Các lớp còn lại được phân loại hoàn toàn chính xác.

3.4.3. Supplied test set

Sử dụng tập dữ liệu kiểm thử

3.4.3.1. Kết quả thu được

```
Correctly Classified Instances         162               99.3865 %
Incorrectly Classified Instances         1                0.6135 %
Kappa statistic                          0.9872
Mean absolute error                      0.0034
Root mean squared error                  0.0501
Relative absolute error                  1.4166 %
Root relative squared error             14.5041 %
Total Number of Instances              163

=== Detailed Accuracy By Class ===

                 TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
                 1,000    0,007    0,929      1,000    0,963      0,960    1,000     0,995     physical, sexual
                 1,000    0,000    1,000      1,000    1,000      1,000    1,000     1,000     physical
                 0,991    0,000    1,000      0,991    0,996      0,986    1,000     1,000     physical, emotional
                 1,000    0,000    1,000      1,000    1,000      1,000    1,000     1,000     emotional
Weighted Avg.    0,994    0,001    0,994      0,994    0,994      0,987    1,000     1,000

=== Confusion Matrix ===

   a   b   c   d   <-- classified as
  13   0   0   0 |   a = physical, sexual
   0   9   0   0 |   b = physical
   1   0 113   0 |   c = physical, emotional
   0   0   0  27 |   d = emotional
```

3.4.3.2. Nhận xét

- Thống kê:

  + Correctly Classified Instances: mô hình cho ra độ chính xác cao 99,34%.
  + Incorrectly Classified Instances: Chỉ có 3 mẫu bị phân loại sai
  + Kappa statistic (Thống kê Kappa): Chỉ số Kappa rất cao là 0.9872, cho thấy sự hiệu quả với mô hình dự đoán ngẫu nhiên
  + Mean absolute error (Sai số trung bình tuyệt đối): 0.0034, cho thấy sự khác biệt trung bình giữa dự đoán và giá trị thực là rất nhỏ
  + Root mean squared error (Căn bậc hai của sai số trung bình bình phương): 0.0501, thể hiện độ lệch bình phương giữa dự đoán và thực tế cũng khá thấp.
  + Relative absolute error (Sai số tuyệt đối tương đối): 1.4166%, thể hiện sai số thấp giữa xác suất dự đoán của mô hình và thực tế
  + Root relative squared error (Căn bậc hai của sai số bình phương tương đối): 14.5041%
- Các độ đo theo lớp:
  + Lớp "physical, sexual": Precision là 0.929, Recall 1.0, F-measure 0.963, với FP Rate rất thấp là 0.007. Điều này cho thấy mô hình có thể phân loại đúng nhưng có một số nhầm lẫn nhỏ với các lớp khác.
  + Lớp "physical" và "emotional": Precision, Recall, F-Measure đều đạt 1.0, cho thấy mô hình này phân loại cực kỳ chính xác cho hai lớp này.
  + Lớp "physical, emotional": Precision và F-measure vẫn cao, nhưng Recall giảm nhẹ xuống 0.991.
- Ma trận nhầm lẫn: Có duy nhất một trường hợp bị phân loại nhầm. Điều này thể hiện rõ trong ma trận nhầm lẫn ở lớp "physical, emotional", khi 1 mẫu được phân loại nhầm vào lớp "physical, sexual". Không có bất kỳ lỗi phân loại nào giữa các lớp "physical" và "emotional".

3.4.4. Cây quyết định

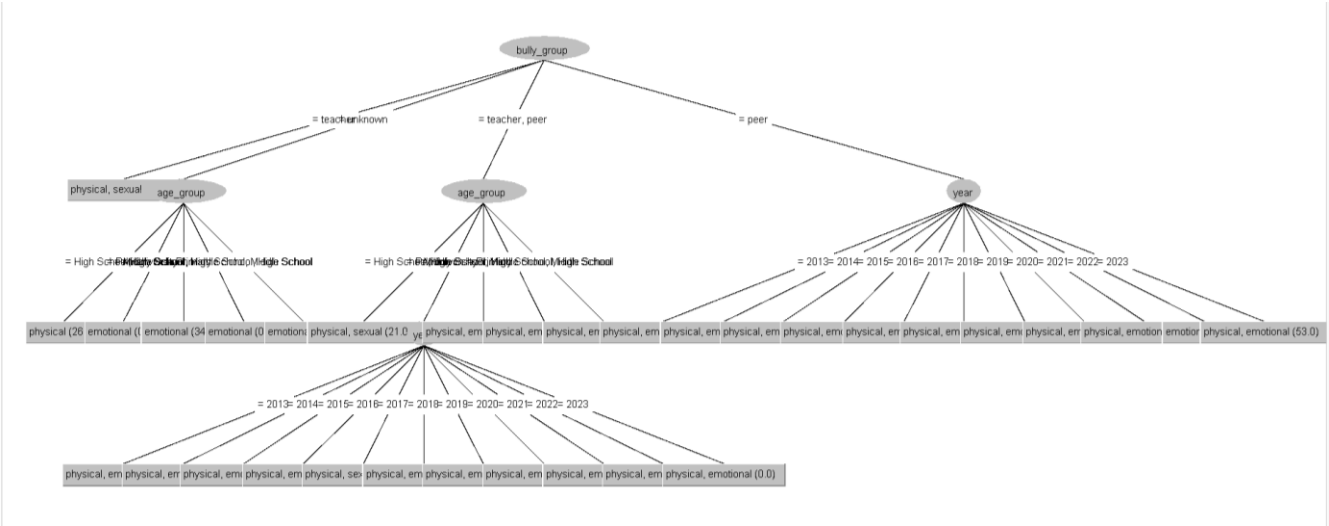

3.5. Nhận xét

Mô hình phân loại bắt đầu với nút gốc là *bully_group*, cho thấy độ ảnh hưởng đối tượng gây ra bạo lực là quan trọng nhất, tiếp đến là *age_group* và *year* theo từng nhánh. Thuộc tính *incomegroup* (nhóm thu nhập) và *gender* (giới tính) không xuất hiện trong cây.

⇒ Điều này cho thấy các yếu tố độ tuổi và người gây ra bạo lực có vai trò quan trọng trong việc dự đoán loại bạo lực.

Bên cạnh đó, *year* (năm khảo sát) cũng ảnh hưởng tới các nút lá, điều này có ý nghĩa về sự thay đổi xu hướng bạo lực theo thời gian.

3.6. Đánh giá

Đối với bài toán phân tích mối quan hệ giữa các yếu tố như giới tính, độ tuổi và loại bạo lực để xác định những yếu tố quan trọng nhất dẫn tới bạo lực học đường, việc sử dụng thuật toán ID3 là một lựa chọn hợp lý. Bởi vì dữ liệu trong bài toán này có cấu trúc rõ ràng và có mối liên kết logic giữa các thuộc tính như giới tính, độ tuổi và các hình thức bạo lực. ID3 giúp xây dựng một cây quyết định có thể dễ hiểu và trực quan, dễ dàng giải thích quá trình phân loại và đưa ra các yếu tố quan trọng ảnh hưởng đến hành vi bạo lực.

Tuy nhiên, tương tự như các thuật toán khác, ID3 cũng có những hạn chế. Một trong những điểm yếu chính của thuật toán này là khi làm việc với tập dữ liệu lớn và phức tạp, nó dễ gặp hiện tượng quá khớp (overfitting).

Ngoài ra, với những dữ liệu có nhiều thuộc tính và sự tương tác phức tạp giữa các yếu tố, ID3 có thể bỏ sót một số quy tắc quan trọng.

Tóm lại, việc sử dụng ID3 cho bài toán phân tích bạo lực học đường là một lựa chọn phù hợp. Tuy nhiên, cần lưu ý xử lý hiện tượng quá khớp (overfitting) và cân nhắc sử dụng các biến thể của thuật toán để đạt được kết quả chính xác và khả năng tổng quát hóa tốt nhất.

PHẦN IV. TRIỂN KHAI THUẬT TOÁN

1. Triển khai thuật toán (Python)

```
import pandas as pd
from scipy.io import arff
from sklearn.preprocessing import LabelEncoder
from sklearn.tree import DecisionTreeClassifier, plot_tree
import matplotlib.pyplot as plt

data, meta = arff.loadarff('finalfinalfinal.arff')

df = pd.DataFrame(data)

print(df.head())

for col in df.columns:
    if df[col].dtype == object:
        df[col] = df[col].apply(lambda x: x.decode('utf-8'))

label_encoders = {}
for column in df.columns:
    if df[column].dtype == 'object':
        le = LabelEncoder()
        df[column] = le.fit_transform(df[column])
        label_encoders[column] = le

X = df.drop(columns='violence_type')
y = df['violence_type']

clf = DecisionTreeClassifier(criterion='entropy')
clf.fit(X, y)
```

- Kết quả cây quyết định:

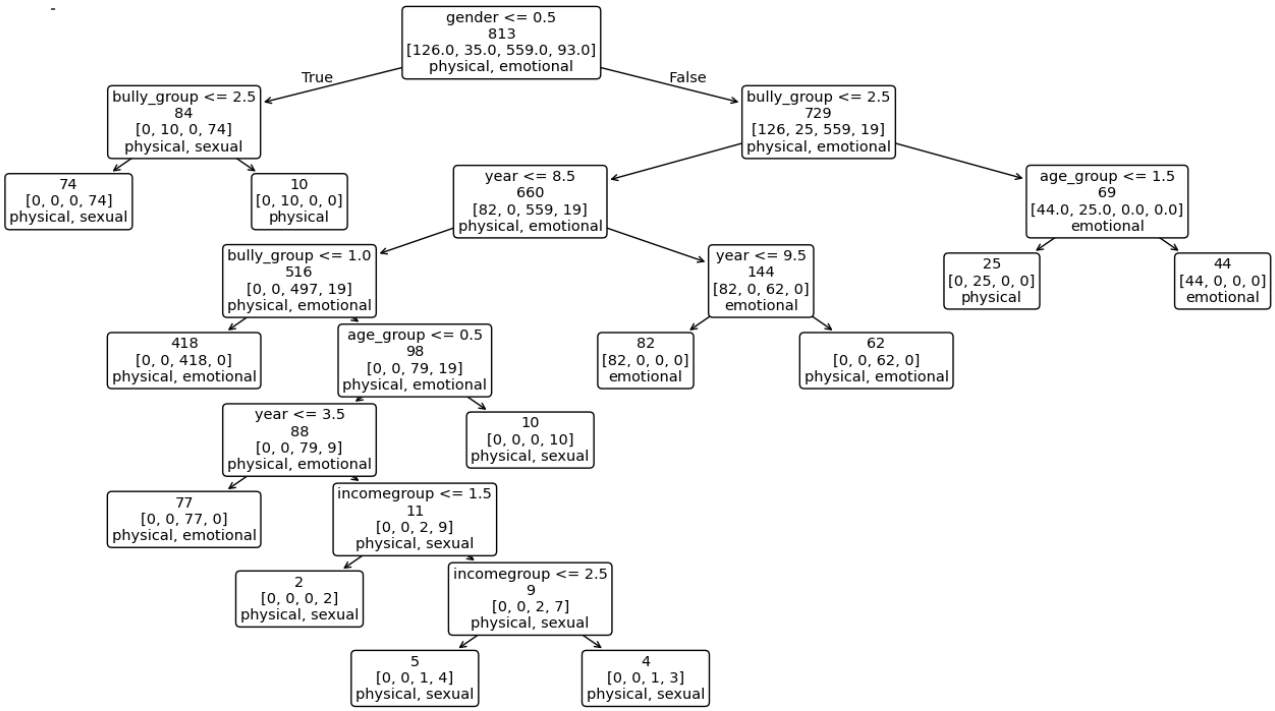

- Khi sử dụng LabelEncoder để mã hóa các giá trị chuỗi thành số, chúng sẽ được chuyển đổi như sau:
- *income_group*:

'Low income' → 0

'Lower middle income' → 1

'Upper middle income' → 2

'High income' → 3

- *year*:

2013 → 0

2014 → 1

2015 → 2

2016 → 3

2017 → 4

2018 → 5

2019 → 6

2020 → 7

2021 → 8

2022 → 9

2023 → 10

- *gender*:

0 → 0 (female)

1 → 1 (male)

- *violence_type*:

'physical, sexual' → 0

'physical' → 1

'physical, emotional' → 2

'emotional' → 3

- *age_group*:

'Primary School, Middle School' → 0

'Primary School, Middle School, High School' → 1

'Middle School, High School' → 2

'High School' → 3

'High School, University' → 4

- *bully_group*:

'teacher' → 0

'unknown' → 1

'teacher, peer' → 2

'peer' → 3

2. Sử dụng mô hình để dự đoán kết quả

- Nhập Gender

- Nhập Year
- Nhập Income Group
- Nhập Bully Group
- Nhập Age Group

```
gender = input(f"Gender (Enter one: {list(label_encoders['gender'].classes_)}): ")
year = input(f"Year (Enter a value from 2013 to 2023): ")
income_group = input(f"Income Group (Choose one: {list(label_encoders['income_group'].classes_)}): ")
bully_group = input(f"Bully Group (Choose one: {list(label_encoders['bully_group'].classes_)}): ")
age_group = input(f"Age Group (Choose one: {list(label_encoders['age_group'].classes_)}): ")

user_input = {
    'gender': [gender],
    'year': [year],
    'income_group': [income_group],
    'bully_group': [bully_group],
    'age_group': [age_group]
}

user_df = pd.DataFrame(user_input)
```

- Sau khi nhập dữ liệu đầu vào tương ứng ở trên , mô hình sẽ sử dụng hàm dự đoán trong code (xem chi tiết ở file đính kèm) để cho ra kết quả:

Nhãn	Output
physical, sexual	Đây là nhãn chỉ ra rằng hành vi bạo lực bao gồm cả **bạo lực thể chất** và **bạo lực tình dục**
physical	Nhãn này chỉ ra hành vi **bạo lực thể chất**
physical, emotional	Nhãn này mô tả hành vi bao gồm cả **bạo lực thể chất** và **bạo lực tinh thần**
emotional	Nhãn này chỉ ra hành vi bạo lực là **bạo lực tinh thần**

- Trường hợp dữ liệu không nằm trong phạm vi dự đoán:

  Kết quả sẽ trả về: Unpredictable

```
Enter the following information:
Gender (Enter one: ['0', '1']): 3
Year (Enter a value from 2013 to 2023): 2012
Income Group (Choose one: ['High income', 'Low income', 'Lower middle income', 'Upper middle income']): Low income
Bully Group (Choose one: ['peer', 'teacher', 'teacher, peer', 'unknown']): peer
Age Group (Choose one: ['High School', 'High School, University', 'Middle School, High School', 'Primary School, Middle School', 'Primary Sch
ool, Middle School, High School']): High School
Unrecognized label in column 'gender'. Please provide a valid value.
Unpredictable
```

- Thực hành chạy code dự đoán:

```
Enter the following information:
Gender (Enter one: ['0', '1']): 1
Year (Enter a value from 2013 to 2023): 2012
Income Group (Choose one: ['High income', 'Low income', 'Lower middle income', 'Upper middle income']): Low income
Bully Group (Choose one: ['peer', 'teacher', 'teacher, peer', 'unknown']): peer
Age Group (Choose one: ['High School', 'High School, University', 'Middle School, High School', 'Primary School, Middle School', 'Primary Sch
ool, Middle School, High School']): High School
Predicted violence type: physical, emotional
```

KẾT LUẬN

Sau khi hoàn thành đề tài *"Khai phá dữ liệu về bạo lực học đường",* nhóm chúng em đã đạt được một số kết quả như sau:

- Tổng quan: Nhóm đã tìm hiểu các khái niệm như tiền xử lý, phương pháp phân lớp và đặc biệt là thuật toán ID3 để xây dựng cây quyết định, qua đó tìm hiểu được mối liên hệ giữa các yếu tố dẫn tới bạo lực học đường.
- Nhóm đã thu thập và xử lý dữ liệu liên quan đến bạo lực học đường bằng các công cụ Weka và Python. Quá trình tiền xử lý giúp làm sạch và chuẩn hóa dữ liệu để đảm bảo tính chính xác cho mô hình.
- Nhóm đã xây dựng thành công mô hình phân lớp bằng thuật toán ID3 trên phần mềm Weka và Python.

Mặc dù nhóm đã cố gắng hoàn thiện đề tài, nhưng vẫn còn những thiếu sót và hạn chế trong quá trình thực hiện. Chúng em mong muốn nhận được sự góp ý và chỉ dẫn từ các thầy cô để cải thiện kỹ năng, kiến thức và có thể ứng dụng tốt hơn các phương pháp khai phá dữ liệu trong các dự án thực tế trong tương lai.

TÀI LIỆU THAM KHẢO

1. Dữ liệu thô: Introducing a New Dataset of Datasets: Where, When, and How Much Data Exists on School Violence | Center For Global Development (cgdev.org)
2. Trần Mạnh Tuấn, Slide bải giảng Khai phá dữ liệu
3. Trần Mạnh Tuấn, Hoàng Thị Minh Châu, Trần Thanh Đại, Vũ Mỹ Hạnh, Vũ Anh Tuấn, 2022, Giáo trình khai phá dữ liệu, Trường Đại học Kinh tế - Kỹ thuật Công nghiệp.